sherpa.

Гипотезы

как находить и тестировать идеи в продукте

Практическое руководство

Содержание

01 Формулировка бизнес-цели 5

02 Целевые метрики успеха: North Star и вспомогательные 10

03 Анализ ограничений и ресурсов 15

04 Анализ текущих продуктовых метрик 20

05 Качественные исследования 26

06 Количественные исследования 31

07 Анализ конкурентов и рынка 36

08 Структура гипотезы 40

09 Критерии приоритизации 44

10 Продуктовые, маркетинговые и технические гипотезы 48

11 Оценка влияния на ключевые метрики 52

12 Оценка сложности и стоимости реализации 57

13 Формирование тестового бэклога 62

14 Определение метода тестирования 67

15 Выбор аудитории и сегментов 72

16 Выбор длительности теста 76

17 План сбора данных и фиксации результатов 81

18 Настройка трекинга и аналитики 85

19 Мониторинг ключевых метрик в процессе 90

20 Реагирование на аномалии и фейлы 94

21 Статистическая значимость и доверительные интервалы 99

22 Интерпретация в контексте гипотезы и метрик 104

23 Выявление побочных эффектов и непредвиденных изменений 109

24 **Критерии «Запускаем / Дорабатываем / Отказываемся»** 113

25 **Документирование результатов** 118

26 **Обновление бэклога гипотез** 123

27 **Постепенное расширение на другие сегменты** 127

28 **Интеграция в основную продуктовую версию** 132

29 **Пост-анализ долгосрочного влияния** 136

30 **Ретроспектива экспериментов** 141

31 **Обновление подходов к поиску идей** 146

32 **Автоматизация сбора данных и тестирования** 150

ПРИЛОЖЕНИЯ

А **Шаблоны документов** 155

Б **Чек-листы по этапам** 158

В **Глоссарий** 160

КАК ЧИТАТЬ

- правило или ключевое число
- важно: типичная ошибка
- мировой кейс или пример из практики
- классика: идея, автор, год
- f формула: сначала общий вид, затем значения символов
- ПРАКТИКА задание после главы

СКВОЗНОЙ КЕЙС проходит через все 32 глав

«Форма»

Мобильное приложение домашних тренировок по подписке. Установок много, но до оплаты доходит малая часть, а платящие уходят через несколько месяцев. Команда годами запускала фичи «по ощущениям» и не могла сказать, какие из них что-то изменили. Продакт-менеджер Ксения получила цель — вырастить выручку на треть за год — и решила перейти от фич к гипотезам. Мы проходим этот путь от цели до непрерывного цикла экспериментов.

ПРОДАКТ-МЕНЕДЖЕР
Ксения
хочет решения на данных, а не на мнениях

АНАЛИТИК
Артур
хочет эксперименты, которым можно верить

ИССЛЕДОВАТЕЛЬ
Лера
хочет, чтобы идеи шли от пользователей

Месяц 599 ₽ **Год** 3 990 ₽ **Триал** 7 дней

Команда продукт, аналитика, дизайн, 9 разработчиков

ВОСЕМЬ ВВОДНЫХ И РЕЗУЛЬТАТ

120 000 установок в месяц	**34%** тренировка в первый день	**18%** начинают пробный период
41% триал → оплата	**520 ₽** средний платёж в месяц	**11%** отток платящих в месяц
64 000 платящих подписчиков	**33,3 млн ₽** выручка в месяц (MRR)	**33,3 → 45 млн ₽** цель на 12 месяцев: +35% MRR

Приложение вымышлено, но собрано из типичных ситуаций подписочных продуктов. Числа согласованы: воронка, выручка, размер выборок и эффект экспериментов выводятся друг из друга.

01 Формулировка бизнес-цели

После неё вы переводите пожелание руководства в цель с числом, сроком и рычагами, раскладываете её по воронке и понимаете, какие гипотезы вообще имеет смысл искать.

1.1 Из пожелания в цель · 1.2 Декомпозиция выручки · 1.3 Кейс «Формы»: дерево цели · 1.4 Формулировки: плохо и хорошо · 1.5 Бенчмарки · 1.6 Анти-паттерны · 1.7 Модель цели в таблице · 1.8 Вопросы для самопроверки

Гипотезы без цели превращаются в перебор идей: команда тестирует цвет кнопки, онбординг и новые тарифы одновременно, и через квартал не может сказать, приблизилась ли она к чему-то важному. Цель задаёт направление поиска. Она отвечает на вопрос, какой результат бизнеса мы хотим изменить, насколько и к какому сроку.

В «Форме» исходное пожелание звучало так: «нужно больше зарабатывать». Это не цель — неясно, сколько, когда и за счёт чего. Ксения потратила неделю, чтобы превратить его в формулировку, с которой можно работать.

1.1 Из пожелания в цель

ШАГ	ВОПРОС	«ФОРМА»
Результат	Что именно растёт?	Ежемесячная выручка от подписок (MRR)
Число	С какого значения до какого?	С 33,3 до 45 млн ₽
Срок	К какой дате?	За 12 месяцев
Рычаги	За счёт каких частей воронки?	Активация, конверсия триала, удержание
Границы	Чего нельзя ухудшать?	Рейтинг в сторах не ниже 4,6, возвраты не выше 2%

1.2 Декомпозиция выручки

ФОРМУЛА 1.1 · ВЫРУЧКА ПОДПИСОЧНОГО ПРОДУКТА

$$MRR = S \cdot ARPPU, \text{ где } S_\infty = \frac{N_{\text{new}}}{q} \tag{1.1}$$

где

S	—	платящих подписчиков	чел.
$ARPPU$	—	средний платёж платящего в месяц	₽
N_{new}	—	новых платящих в месяц	чел.
q	—	месячный отток платящих	доля
S_∞	—	равновесная база при постоянных N и q	чел.

```
Сейчас N = 8 856, q = 11% → S∞ ≈ 80 500 → MRR∞ ≈ 41,9 млн ₽. Если q = 9%, а конверсия триала 45%: N ≈ 9 720, S∞ ≈ 108 000
```

Формула сразу показала главное: даже без новых действий база будет расти к 80 тысячам, но цель 45 млн ₽ так не достигается. Нужно либо больше новых платящих, либо меньше оттока. Отток при этом сильнее: снижение с 11% до 9% поднимает равновесную базу на 22%, а рост новых на те же 22% требует почти удвоить маркетинговый бюджет.

1.3 Кейс «Формы»: дерево цели

КАК КСЕНИЯ РАЗЛОЖИЛА ЦЕЛЬ

1. **Выручка**
   MRR 33,3 → 45 млн ₽ — цель компании.
2. **Ветки**
   Новые платящие (установки × активация × триал × оплата) и удержание (отток).
3. **Рычаги**
   Активация 34 → 40%, триал → оплата 41 → 45%, отток 11 → 9%.
4. **Проверка**
   Модель в таблице: при трёх рычагах MRR через 12 мес. ≈ 46 млн ₽.

КАК КСЕНИЯ РАЗЛОЖИЛА ЦЕЛЬ

✓ **Итог**

Гипотезы ищем только на трёх рычагах; трафик и цены — вне фокуса на полгода.

ПРАВИЛО

Каждая гипотеза должна указывать, какой рычаг цели она двигает. Если связь с целью нельзя назвать одной фразой, гипотеза уходит в «когда-нибудь».

1.4 Формулировки: плохо и хорошо

ПЛОХО

Цель-пожелание

«Увеличить выручку».

«Улучшить удержание».

«Сделать продукт удобнее».

ХОРОШО

Цель с числом и рычагом

«MRR 33,3 → 45 млн ₽ к октябрю».

«Месячный отток платящих 11% → 9% к апрелю».

«Активация 34% → 40% без падения конверсии триала».

1.5 Бенчмарки

МЕТРИКА ПОДПИСОЧНОГО ФИТНЕС-ПРИЛОЖЕНИЯ	ОРИЕНТИР	«ФОРМА»
Установка → старт триала	10–25%	18%
Триал → оплата (без карты на входе)	30–50%	41%
Месячный отток платящих	6–12%	11%
Рост MRR за год у зрелого продукта	20–50%	цель +35%

Ориентиры собраны по открытым отчётам о подписочных приложениях и сильно зависят от модели триала, страны и цены. Их задача — показать, где продукт заметно отстаёт, а не задать цель.

1.6 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Цель без числа	Невозможно понять, достигнута ли	Значение «с — до» и срок
Пять целей сразу	Команда распыляется	Одна цель и 2–3 рычага
Нет границ	Рост выручки за счёт обмана пользователей	Защитные метрики
Цель не разложена	Гипотезы не связаны с результатом	Дерево цели до рычагов

1.7 Модель цели в таблице

МЕСЯЦ	НОВЫХ ПЛАТЯЩИХ	ОТТОК	БАЗА	MRR, МЛН ₽
0	8 856	11%	64 000	33,3
3	9 100	10,5%	70 400	36,6
6	9 400	10%	76 100	39,6
9	9 600	9,5%	81 000	42,1
12	9 720	9%	88 500	46,0

Таблица строится помесячно: база следующего месяца равна базе текущего минус отток плюс новые платящие. Рычаги меняются постепенно, потому что каждый выигрышный эксперимент добавляет немного. Модель стала инструментом разговора с руководством: любую гипотезу можно было «подставить» и увидеть её вклад в итоговую цифру.

МИРОВОЙ КЕЙС Duolingo, 2018–2022

Цель через рычаги, а не через фичи

Команда роста Duolingo, по рассказам её руководителей, разложила рост ежедневно активных пользователей на сегменты: новые, вернувшиеся, текущие — и обнаружила, что сильнее всего на итог влияет удержание текущих пользователей.

Фокус на одном рычаге привёл к серии экспериментов с сериями занятий и лигами, которые за несколько лет многократно увеличили активную аудиторию.

ПРИМЕР

Онлайн-школа

Школа английского хотела «больше учеников». Разложение выручки показало: 70% денег дают продления, а их доля упала с 64% до 52%. Цель переформулировали как «продления 52% → 60% за полгода», и бэклог из 80 идей про рекламу сократился до 15 гипотез про первые месяцы обучения.

1.8 Вопросы для самопроверки

- Можно ли считать целью «вырасти в два раза»? Чего не хватает?
- Почему снижение оттока часто сильнее роста новых платящих?
- Зачем в цели защитные границы?
- Как проверить, что рычаги вообще могут дать нужный результат?
- Что делать с гипотезой, которую нельзя связать ни с одним рычагом?

ПРАКТИКА 1 после главы 01

Превратите пожелание руководства в цель и разложите её до рычагов.

ЧТО СДЕЛАТЬ

01	Запишите результат, число «с — до», срок и границы.	☐
02	Разложите результат формулой на части воронки.	☐
03	Посчитайте, сколько даёт изменение каждого рычага на 10%.	☐
04	Выберите 2–3 рычага с наибольшей отдачей.	☐
05	Проверьте модель: достигается ли цель при реалистичных изменениях рычагов?	☐

РЕЗУЛЬТАТ Если цель не достигается даже на бумаге, обсудите её с руководством до первого эксперимента.

02 Целевые метрики успеха: North Star и вспомогательные

После неё вы выбираете North Star метрику, которая отражает ценность для пользователя и ведёт к выручке, строите вокруг неё дерево метрик и задаёте защитные метрики для экспериментов.

2.1 Свойства хорошей North Star
2.2 Кейс «Формы»: выбор звезды
2.3 Дерево метрик
2.4 Три роли метрик в эксперименте
2.5 Анти-паттерны
2.6 Проверка связи звезды с выручкой
2.7 Вопросы для самопроверки

Выручка — итоговая метрика, но плохой ориентир для ежедневной работы: она меняется медленно и зависит от множества причин. Команде нужна метрика, которая быстро реагирует на изменения продукта, отражает ценность для пользователя и при этом тянет за собой выручку. Такую метрику называют North Star — путеводной звездой.

2.1 Свойства хорошей North Star

Отражает ценность	Пользователь получил то, ради чего пришёл: послушал музыку, доставил заказ, провёл тренировку.
Предсказывает выручку	Рост метрики сегодня означает рост выручки через месяцы.
Чувствительна	Меняется на горизонте недель, а не кварталов, — на неё можно влиять экспериментами.
Понятна	Её можно объяснить одной фразой любому в компании.

2.2 Кейс «Формы»: выбор звезды

КАНДИДАТ	ЦЕННОСТЬ	СВЯЗЬ С ВЫРУЧКОЙ	ПОЧЕМУ НЕТ / ДА
Установки	нет	слабая	Растут от рекламы, а не от продукта

КАНДИДАТ	ЦЕННОСТЬ	СВЯЗЬ С ВЫРУЧКОЙ	ПОЧЕМУ НЕТ / ДА
MAU	частично	средняя	Открыл и закрыл — тоже активный
Тренировок в месяц	да	средняя	Десять тренировок в один день искажают картину
Тренирующиеся ≥2 раз в неделю	да	сильная	Отток у них 6% против 19% у остальных — выбрали

Артур выгрузил историю: у платящих, которые тренируются хотя бы дважды в неделю, месячный отток 6%, у остальных платящих — 19%. Метрика «еженедельно тренирующиеся» (WAT) сейчас равна 96 000. Если поднять долю регулярных среди платящих, отток упадёт, и выручка вырастет.

2.3 Дерево метрик

```
MRR (итог, месяц)
 North Star: еженедельно тренирующиеся (≥2 тренировки), 96 000
  новые: установки → тренировка в 1-й день (34%) → 2-я тренировка за неделю (52%)
  удержание: доля недель с ≥2 тренировками у платящих (58%)
  возврат: вернулись после 14 дней паузы (11%)
 монетизация: старт триала (18%) → оплата (41%) · ARPPU 520 ₽
 защитные: рейтинг в сторах ≥ 4,6 · возвраты ≤ 2% · крэши ≤ 0,3%
```

2.4 Три роли метрик в эксперименте

РОЛЬ	ЗАЧЕМ	ПРИМЕР
Целевая (primary)	По ней принимаем решение	Конверсия триала в оплату
Вспомогательные (secondary)	Объясняют, почему изменилась целевая	Доля дошедших до экрана оплаты, отмены в первый день
Защитные (guardrail)	Не дают выиграть ценой вреда	Возвраты, оценки, отток через 30 дней

КЛАССИКА Шон Эллис и Морган Браун, «Hacking Growth», 2017

North Star и игра в рост

Авторы предложили выбирать одну метрику, которая лучше всего отражает ключевую ценность продукта, и строить вокруг неё всю работу команды роста.

Они подчёркивали: если метрика растёт, а пользователи не получают больше ценности, метрика выбрана неверно.

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Выбирать North Star, которая растёт от маркетинга: установки, регистрации, MAU. Тогда эксперименты продукта почти не двигают звезду, а рекламная кампания создаёт ложное ощущение успеха.

ПЛОХО

Метрика активности

«North Star — MAU».

Пуш-уведомление поднимает MAU, но не тренировки.

ХОРОШО

Метрика ценности

«Тренирующиеся ≥2 раз в неделю».

Растёт, только если люди действительно тренируются.

2.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Звезда из маркетинга	Эксперименты продукта её не двигают	Метрика полученной ценности
Нет защитных метрик	Выигрыши за счёт вреда	2–3 защитные на каждый тест
Свою звезду у каждой команды	Команды тянут в разные стороны	Одна звезда, свои ветки дерева
Звезда не связана с выручкой	Рост без денег	Проверить связь на истории

2.6 Проверка связи звезды с выручкой

ДОЛЯ НЕДЕЛЬ С ≥2 ТРЕНИРОВКАМИ В M1	ПЛАТЯЩИХ	ОТТОК В M2	УДЕРЖАНИЕ M6
0–25%	21 000	24%	28%
25–50%	16 000	15%	44%
50–75%	14 000	8%	63%
75–100%	13 000	4%	79%

Связь монотонная: чем регулярнее человек тренируется в первый месяц, тем дольше он платит. Это ещё не доказательство причины — регулярные могут быть изначально мотивированнее. Но это достаточное основание выбрать звезду и проверять экспериментами, что рост регулярности действительно снижает отток.

МИРОВОЙ КЕЙС — Airbnb, Spotify, Slack — публичные выступления команд

Звезда, которая отражает ценность

Airbnb ориентировалась на забронированные ночи, Spotify — на время прослушивания, Slack — на число сообщений в команде. Во всех случаях метрика фиксирует момент, когда пользователь получил ценность, а не просто открыл продукт.

Общий признак: звезду нельзя «накрутить» уведомлениями без того, чтобы люди действительно стали больше пользоваться продуктом.

ПРИМЕР

Сервис доставки

Сервис доставки еды выбрал звездой «заказы в неделю на активного клиента». Через полгода выяснилось, что метрика растёт за счёт скидочных мелких заказов с отрицательной маржой. Звезду заменили на «заказы с положительной маржой» и добавили защитную метрику средней маржи заказа.

2.7 Вопросы для самопроверки

- Чем North Star отличается от выручки как ориентира?
- Почему MAU — плохая звезда для большинства продуктов?

- Как на истории проверить связь звезды с выручкой?
- Зачем эксперименту три роли метрик?
- Что делать, если звезда растёт, а выручка нет?

ПРАКТИКА 2 после главы 02

Выберите North Star и постройте дерево метрик.

ЧТО СДЕЛАТЬ

01	Выпишите 3–5 кандидатов в North Star.	☐
02	Проверьте каждого по четырём свойствам.	☐
03	На истории сравните отток или выручку у пользователей с высоким и низким значением кандидата.	☐
04	Постройте дерево: звезда → ветки → рычаги → защитные метрики.	☐

РЕЗУЛЬТАТ Повесьте дерево на стену или в общий документ — к нему вы будете возвращаться в каждой главе.

03 Анализ ограничений и ресурсов

После неё вы оцениваете трафик, время команды, технические и юридические ограничения и понимаете, сколько экспериментов реально провести за квартал.

3.1 Пять видов ограничений
3.2 Пропускная способность
3.3 Кейс «Формы»: карта ёмкости
3.4 Бенчмарки
3.5 Анти-паттерны
3.6 Что делать при малом трафике
3.7 Вопросы для самопроверки

Ограничения определяют, какие гипотезы можно проверить и как. Маленький трафик не позволит A/B-тестировать мелкие изменения, нехватка разработчиков ограничит число тестов, а правила сторов и закон о персональных данных закроют часть идей сразу. Лучше узнать об этом до того, как бэклог заполнится сотней идей.

3.1 Пять видов ограничений

ОГРАНИЧЕНИЕ	ВОПРОС	«ФОРМА»
Трафик	Сколько пользователей проходит через точку теста в неделю?	27 600 установок, 5 000 стартов триала
Люди	Сколько часов в спринт команда готова отдать экспериментам?	2 разработчика из 9, аналитик на 60%
Техника	Есть ли инструмент раздачи вариантов и сбора событий?	Флаги есть, сплит-тестов на сервере нет
Платформы	Что разрешают App Store и Google Play?	Цены и триалы меняются через стор, ревью 1–3 дня
Право и этика	Что запрещено законом и политиками?	Нельзя менять цену у части пользователей без раскрытия; согласие на обработку данных

3.2 Пропускная способность

Главное ограничение почти всегда — трафик в точке теста. От него зависит, сколько тестов можно провести последовательно на одном экране. Артур посчитал для экрана оплаты: при базовой конверсии 41% и минимальном интересном эффекте 3 п.п. нужно около 4 300 триалов на группу, то есть 8 600 на тест — меньше двух недель трафика.

ФОРМУЛА 3.1 · СКОЛЬКО ТЕСТОВ ПОМЕСТИТСЯ В КВАРТАЛ

$$K = \frac{W \cdot T_{\text{нед}}}{2 \cdot n} \tag{3.1}$$

где

W	—	недель в периоде	нед.
$T_{\text{нед}}$	—	пользователей в точке теста в неделю	чел.
n	—	нужный размер группы	чел.

```
Экран оплаты: 13 · 5 000 / (2 · 4 300) ≈ 7,6 → не больше 7 последовательных тестов в квартал, с учётом полных недель — 6
```

3.3 Кейс «Формы»: карта ёмкости

ЧТО ВЫЯСНИЛА КСЕНИЯ

1. **Точки теста**
   Онбординг, первая тренировка, экран триала, экран оплаты, напоминания, экран отмены.

2. **Ёмкость**
   Онбординг — 20 тестов в квартал, экран отмены — только 2: туда доходит 1 900 человек в неделю.

3. **Люди**
   2 разработчика на эксперименты → 8–10 тестов в квартал по реализации.

✓ **Вывод**
Узкое место — разработка, а не трафик; на экране отмены — трафик, поэтому там нужны крупные изменения.

ПРАВИЛО

Считайте ёмкость каждой точки теста до заполнения бэклога. Гипотезу, для проверки которой нужно полгода трафика, лучше сразу переформулировать в более смелую или проверять другим методом.

ПЛОХО

Бэклог без ёмкости

40 гипотез для экрана отмены.

Каждая требует 9 недель трафика.

ХОРОШО

Бэклог по ёмкости

Для экрана отмены — 2 смелых изменения в квартал.

Мелкие идеи — в интервью и прототипы.

3.4 Бенчмарки

ПОКАЗАТЕЛЬ	ОРИЕНТИР	«ФОРМА»
Доля разработки на эксперименты в продуктовой команде	15–30%	22%
Экспериментов в квартал на команду	6–15	цель 10–12
Время на настройку одного A/B-теста	1–3 дня	до 5 дней сейчас

3.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Игнорировать трафик	Тесты без результата месяцами	Считать ёмкость по формуле (3.1)
Эксперименты «в свободное время»	Тесты не запускаются	Явная доля разработки
Не учитывать сторы	Тест цены отклонён на ревью	Проверить правила заранее

3.6 Что делать при малом трафике

СИТУАЦИЯ	ВМЕСТО МЕЛКОГО A/B	ПРИМЕР
Мало трафика в точке	Смелые изменения с большим ожидаемым эффектом	Новый экран отмены целиком, а не текст кнопки
Долгий цикл метрики	Опережающая метрика	Тренировки в первую неделю вместо оттока M2
Нет инструмента сплита	Фича-флаг и сравнение по дням или регионам	Последовательный запуск с контролем сезонности
Идея дорогая	Фейковая дверь, прототип, ручная проверка	Кнопка «тренер в чате» с опросом вместо разработки

Для экрана отмены Ксения выбрала именно смелые изменения: вместо пяти мелких тестов текстов — два крупных варианта, каждый с ожидаемым эффектом 5–8 п.п. Такие эффекты видны на 2 000 пользователях в группе, то есть за два месяца трафика, а не за полгода.

ПРИМЕР

B2b-сервис

SaaS для бухгалтерии с 900 новыми клиентами в месяц не мог тестировать мелкие изменения: на тест кнопки нужен был год. Команда перешла на крупные изменения онбординга, интервью и тесты по когортам месяцев с контролем сезонности — и за год провела 9 проверок вместо 2.

3.7 Вопросы для самопроверки

- Какое ограничение чаще всего становится узким местом?
- Как посчитать, сколько тестов поместится на экран за квартал?
- Что делать с точкой, где тест требует полгода трафика?
- Почему эксперименты «в свободное время» не запускаются?
- Какие ограничения сторов важно знать заранее?

ПРАКТИКА 3 после главы 03

Составьте карту ёмкости своих точек теста.

ЧТО СДЕЛАТЬ

01	Выпишите точки продукта, где вы хотите тестировать.	☐
02	Посчитайте недельный трафик в каждой.	☐
03	Оцените размер группы и посчитайте ёмкость по формуле (3.1).	☐
04	Добавьте ограничения людей, техники, платформ и права.	☐

РЕЗУЛЬТАТ Карта ёмкости покажет, где нужен A/B-тест, а где — другие методы проверки.

04 Анализ текущих продуктовых метрик

После неё вы строите воронку и когорты, находите места наибольших потерь и превращаете цифры в вопросы, на которые отвечают гипотезы.

4.1 Воронка «Формы» за месяц
4.2 Когорты удержания
4.3 Сегменты
4.4 Кейс «Формы»: три вопроса из данных
4.5 Бенчмарки
4.6 Анти-паттерны
4.7 Вопросы для самопроверки

Лучшие гипотезы рождаются там, где продукт теряет больше всего пользователей или денег. Чтобы найти эти места, нужны три инструмента: воронка показывает, на каком шаге уходят люди; когорты — как меняется поведение со временем; сегменты — у кого всё хорошо, а у кого плохо. Вместе они превращают «конверсия низкая» в конкретный вопрос.

4.1 Воронка «Формы» за месяц

УСТАНОВКИ	**100%** · 120 000 установок	100
ОНБОРДИНГ ПРОЙДЕН	**71%** · 85 200 ответили на анкету и выбрали программу	71
ПЕРВАЯ ТРЕНИРОВКА В 1-Й ДЕНЬ	**34%** · 40 800 начали тренировку	34
СТАРТ ТРИАЛА	**18%** · 21 600 подключили пробный период	18
ОПЛАТА	**7,4%** · 8 856 новых платящих	7

Самая большая относительная потеря — между онбордингом и первой тренировкой: из 85 200 человек, которые выбрали программу, до тренировки доходят 48%. Это первое место для поиска гипотез. Второе — оплата: 59% начавших триал не платят.

4.2 Когорты удержания

КОГОРТА ПЛАТЯЩИХ	M1	M2	M3	M6
Январь	89%	79%	71%	52%
Апрель	88%	78%	70%	—
Июль	90%	80%	—	—
Регулярные (≥2 трен./нед в M1)	96%	91%	87%	74%
Нерегулярные	81%	66%	55%	33%

Когорты по месяцам почти одинаковы — продукт не стал ни лучше, ни хуже. Зато разрыв между регулярными и нерегулярными огромный: через полгода остаётся 74% против 33%. Отсюда вопрос: что мешает новым платящим тренироваться дважды в неделю в первый месяц?

4.3 Сегменты

СЕГМЕНТ	ДОЛЯ УСТАНОВОК	ТРЕНИРОВКА В 1-Й ДЕНЬ	ТРИАЛ → ОПЛАТА
Цель «похудеть»	46%	31%	38%
Цель «сила»	22%	42%	47%
Цель «гибкость, спина»	19%	37%	44%
Без цели (пропустили анкету)	13%	24%	29%

ФОРМУЛА 4.1 · ВКЛАД ШАГА ВОРОНКИ В ВЫРУЧКУ

$$\Delta MRR = U \cdot \Pi c_i \cdot \frac{\Delta c_k}{c_k} \cdot ARPPU \qquad (4.1)$$

где

U	–	установок в месяц	чел.
Πc_i	–	сквозная конверсия до оплаты	доля
$\Delta c_k / c_k$	–	относительный рост конверсии шага k	доля

Рост конверсии «онбординг → тренировка» на 10% даёт +886 платящих в месяц → +460 тыс. ₽ MRR через месяц и больше по мере накопления базы

4.4 Кейс «Формы»: три вопроса из данных

ЧТО КСЕНИЯ ВЫНЕСЛА ИЗ МЕТРИК

1 **Потеря после онбординга**
Почему 52% выбравших программу не начинают тренировку в первый день?

2 **Сегмент «похудеть»**
Почему крупнейший сегмент тренируется и платит хуже остальных?

3 **Регулярность**
Что отличает тех, кто тренируется дважды в неделю в первый месяц?

✓ **Дальше**
Вопросы идут в качественные исследования: цифры показывают где, но не почему.

ПРАВИЛО

Метрики отвечают на вопросы «где» и «у кого», но не «почему». Не пытайтесь угадать причину по графику — превратите её в вопрос для исследования.

ПЛОХО

Наблюдение без вопроса

«Конверсия в оплату 41%, это мало».

Непонятно, с чем сравнивать и что делать.

ХОРОШО

Наблюдение с вопросом

«У цели «похудеть» конверсия 38% против 47% у «силы». Почему?»

Ясно, кого исследовать и что сравнивать.

4.5 Бенчмарки

ШАГ	ОРИЕНТИР ДЛЯ ФИТНЕС-ПРИЛОЖЕНИЙ	«ФОРМА»
Установка → завершённый онбординг	60–80%	71%
Установка → ключевое действие в 1-й день	30–45%	34%
Удержание платящих M6	45–60%	52%

4.6 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Только средние по продукту	Проблемы сегментов не видны	Разрез по сегментам
Смотреть один месяц	Сезонность принимается за тренд	Когорты и сравнение периодов
Угадывать причину по графику	Гипотеза на ложном основании	Вопрос → исследование
Сто метрик в дашборде	Важное тонет	Дерево метрик из главы 2

МИРОВОЙ КЕЙС Facebook, ранние 2010-е; рассказы команды роста

Магическое число активации

Команда роста Facebook, по воспоминаниям её участников, обнаружила, что пользователи, добавившие несколько друзей за первые дни, остаются гораздо чаще. Это стало ориентиром для онбординга.

Сам Чамат Палихапития позже подчёркивал, что такое число — упрощение для фокуса команды, а не закон: оно найдено в корреляциях и подтверждалось экспериментами.

Для «Формы» аналогичный ориентир — две тренировки в первую неделю. Артур проверил пороги от одной до четырёх: удержание M2 растёт резко между одной и двумя

тренировками и почти не меняется дальше. Значит, цель онбординга — довести человека до второй тренировки, а не до максимальной активности.

ПРИМЕР

Маркетплейс

Маркетплейс увидел, что конверсия в покупку на Android ниже, чем на iOS, на 30%. Вместо гипотез про дизайн аналитики разрезали воронку по версиям ОС и нашли падение на одном шаге — оплате — у старых версий. Причина оказалась технической, исправление вернуло 4% выручки.

4.7 Вопросы для самопроверки

- Чем вопрос «где» отличается от вопроса «почему»?
- Как найти шаг воронки с наибольшим вкладом в выручку?
- Зачем когорты разрезать по поведению в первую неделю?
- Почему опасно угадывать причину по графику?
- Что делать с сегментом, который сильно хуже среднего?

ПРАКТИКА 4 после главы 04

Найдите в своих метриках три места, где продукт теряет больше всего.

ЧТО СДЕЛАТЬ

01	Постройте воронку от первого контакта до оплаты за последний месяц.	☐
02	Посчитайте вклад каждого шага в выручку по формуле (4.1).	☐
03	Постройте когорты удержания и разрежьте их по поведению в первую неделю.	☐
04	Сравните 3–4 сегмента по ключевым шагам.	☐
05	Сформулируйте три вопроса «почему» для исследований.	☐

РЕЗУЛЬТАТ Хороший вопрос называет шаг, сегмент и разницу в цифрах.

05 Качественные исследования

После неё вы проводите интервью, юзабилити-тесты и анализ обращений так, чтобы найти причины, стоящие за цифрами, и не принимать вежливость респондентов за подтверждение идей.

5.1 Методы · 5.2 Как спрашивать · 5.3 Кейс «Формы»: 12 интервью с «похудеть» · 5.4 Анализ обращений · 5.5 Анти-паттерны · 5.6 Гайд интервью «вечер установки» · 5.7 Вопросы для самопроверки

Качественные исследования отвечают на вопрос «почему». Они работают на малых выборках — пять-двенадцать человек — и не дают процентов, зато показывают мотивы, страхи и реальные сценарии использования. Именно из них приходят самые сильные гипотезы: команда видит проблему, о которой не догадывалась.

5.1 Методы

Метод	Отвечает на вопрос	Сколько людей	Срок
Глубинное интервью	Как человек решает задачу и что ему мешает	8–12 на сегмент	1–2 недели
Юзабилити-тест	Где интерфейс ломает сценарий	5–8	3–5 дней
Дневниковое исследование	Как меняется поведение за недели	10–15	2–4 недели
Анализ обращений и отзывов	На что жалуются сами	сотни текстов	2–3 дня
Интервью с ушедшими	Почему перестали пользоваться	8–10	1 неделя

5.2 Как спрашивать

Главное правило интервью — спрашивать о прошлом поведении, а не о будущих намерениях. «Купили бы вы...» и «Было бы удобно, если...» дают вежливое «да», которое

ничего не стоит. «Расскажите, как прошла ваша последняя тренировка» даёт факты.

КЛАССИКА

Роб Фицпатрик, «The Mom Test», 2013

Тест маминого одобрения

Фицпатрик сформулировал три правила: говорите о жизни человека, а не о вашей идее; спрашивайте о конкретных случаях в прошлом, а не о мнениях о будущем; больше слушайте.

Даже мама не сможет соврать вам, если вы спрашиваете о том, что она делала на прошлой неделе, а не о том, нравится ли ей ваша идея.

ПЛОХО

Вопросы о будущем

«Вам было бы удобно получать напоминание о тренировке?»

«Сколько бы вы заплатили за персональный план?»

ХОРОШО

Вопросы о прошлом

«Вспомните, когда вы в последний раз пропустили тренировку. Что произошло?»

«На что вы тратили деньги, чтобы заниматься спортом, за последний год?»

5.3 Кейс «Формы»: 12 интервью с «похудеть»

Лера провела 12 интервью с пользователями сегмента «похудеть», которые выбрали программу, но не начали тренировку в первый день. Шестеро — недавно установившие, шестеро — ушедшие. Разговор строился вокруг вечера установки: что человек делал, где был, что видел в приложении.

ЧТО НАШЛИ

1. **Страх уровня**
   9 из 12 увидели первую тренировку «35 минут, средний уровень» и решили, что не потянут.

2. **Неподходящее место**
   7 из 12 ставили приложение вечером в постели и откладывали «на завтра».

3. **Нет инвентаря**
   4 из 12 увидели гантели на превью и закрыли.

ЧТО НАШЛИ

✓ **Гипотезы**
Короткая первая тренировка без инвентаря; план на завтра с напоминанием вместо «начать сейчас».

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Показывать респонденту прототип своей идеи в начале интервью. После этого разговор идёт о прототипе, а не о жизни человека, и вы получаете оценку дизайна вместо понимания проблемы. Прототип — в конце или на отдельной встрече.

5.4 Анализ обращений

Параллельно Лера разметила 640 отзывов из сторов за полгода. Самые частые темы среди негативных: «слишком сложно для начинающих» (22%), «списали деньги после пробного периода» (18%), «однообразные тренировки» (14%). Первая тема подтвердила интервью, вторая стала источником гипотез про экран триала.

5.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Вопросы о будущем	Ложные подтверждения	Прошлое поведение
Только лояльные пользователи	Не видны причины ухода	Интервью с ушедшими и непоказавшими
Проценты из 10 интервью	Ложная точность	Количественная проверка
Отчёт на 60 слайдов	Никто не читает	Топ-5 находок с цитатами

5.6 Гайд интервью «вечер установки»

1. Расскажите, почему вы решили установить приложение именно тогда?
2. Где вы были, что делали в тот момент?
3. Что вы делали до этого, чтобы заниматься спортом? Что получилось, что нет?
4. Проведите меня по экранам: что вы увидели после анкеты? (показать запись)
5. Что вы подумали, когда увидели первую тренировку?
6. Что произошло дальше — в тот вечер и на следующий день?
7. Если бы вы рассказывали подруге о приложении, что бы сказали?

Не спрашиваем: «понравилось ли», «купили бы», «было бы удобно, если…»

ПРИМЕР

Финтех

Банковское приложение спрашивало пользователей, нужен ли им «аналитический раздел расходов». 80% ответили «да». После запуска им пользовались 6%. Интервью о том, как люди на самом деле следят за деньгами, показали: им важен один вопрос — «хватит ли до зарплаты», и раздел заменили одной цифрой на главном экране.

5.7 Вопросы для самопроверки

- [ ] Почему вопрос «купили бы вы» бесполезен?
- [ ] Сколько интервью нужно на сегмент и почему не больше?
- [ ] Зачем говорить с теми, кто ушёл?
- [ ] Когда показывать прототип в интервью?
- [ ] Как отличить находку от единичного мнения?

ПРАКТИКА 5 после главы 05

Проведите 8–12 интервью по вопросу из главы 4.

ЧТО СДЕЛАТЬ

01	Выберите сегмент и шаг воронки, где теряются пользователи.	☐
02	Составьте гайд из 8–10 вопросов о прошлом поведении.	☐
03	Проведите интервью и запишите факты, а не мнения.	☐
04	Сгруппируйте находки и посчитайте, у скольких респондентов встретилась каждая.	☐
05	Сформулируйте 2–3 кандидата в гипотезы.	☐

РЕЗУЛЬТАТ Находку, которая встретилась у одного человека из двенадцати, не выбрасывайте, но и не делайте основой гипотезы.

06 Количественные исследования

После неё вы проверяете находки интервью на большой выборке опросами и анализом поведения, правильно строите выборку и не путаете корреляцию с причинностью.

6.1 Методы · 6.2 Размер выборки опроса · 6.3 Кейс «Формы»: опрос после онбординга · 6.4 Корреляция и причинность · 6.5 Анти-паттерны · 6.6 Смещения выборки · 6.7 Вопросы для самопроверки

Качественные исследования показывают, какие причины существуют. Количественные — насколько они распространены. Из двенадцати интервью нельзя понять, боится ли сложной тренировки 75% сегмента или 15%. Для этого нужен опрос на сотнях людей или анализ поведения тысяч пользователей.

6.1 Методы

Опрос в продукте	Короткий вопрос в нужный момент сценария: после закрытия тренировки, при отмене подписки.
Опрос по базе	Рассылка с анкетой; выше риск смещения — отвечают самые вовлечённые.
Анализ поведения	События в аналитике: кто что делал и чем это закончилось.
Конджойнт и MaxDiff	Выбор между наборами характеристик: что важнее для пользователя.

6.2 Размер выборки опроса

ФОРМУЛА 6.1 · ПОГРЕШНОСТЬ ДОЛИ В ОПРОСЕ

$$e = z \cdot \sqrt{\frac{p(1-p)}{n}} \tag{6.1}$$

где

- p — ожидаемая доля ответа — доля
- n — число ответов — шт.
- z — 1,96 для 95% доверия — —
- e — половина ширины интервала — доля

```
p = 0,5; n = 400 → e = 1,96 · √(0,25/400) ≈ 4,9 п.п.; для ±3 п.п. нужно ≈ 1 070 ответов
```

6.3 Кейс «Формы»: опрос после онбординга

Сразу после выбора программы пользователям, которые не начали тренировку в течение 10 минут, приложение задавало один вопрос: «Что помешало начать сейчас?» с пятью вариантами и полем «другое». За неделю ответили 2 140 человек из 11 600 — 18%.

ОТВЕТ	ВСЕ	ЦЕЛЬ «ПОХУДЕТЬ»	ЦЕЛЬ «СИЛА»
Неподходящее время или место	41%	39%	46%
Тренировка выглядит слишком сложной	24%	33%	11%
Нет нужного инвентаря	12%	13%	15%
Хочу сначала посмотреть программу	15%	10%	21%
Другое	8%	5%	7%

Опрос подтвердил обе главные находки интервью и уточнил их масштаб. Страх сложности — проблема прежде всего сегмента «похудеть» (33% против 11%), а неподходящее время — общая для всех. Значит, гипотезы надо делать разными: для «похудеть» — про первую тренировку, для всех — про планирование на завтра.

6.4 Корреляция и причинность

Анализ поведения показал, что пользователи, включившие напоминания, тренируются регулярно в 2,1 раза чаще. Соблазнительно сделать вывод: напоминания повышают регулярность. Но включают их, скорее всего, более мотивированные люди. Данные показывают связь; доказать причину может только эксперимент.

ПРАВИЛО

Любую связь из данных записывайте как гипотезу, а не как вывод. «Напоминания связаны с регулярностью» превращается в «если предлагать напоминания всем, регулярность вырастет» — и проверяется тестом.

ПЛОХО

Вывод из корреляции

«Включившие напоминания тренируются в 2 раза чаще — включим всем по умолчанию».

Эффект может оказаться нулевым или отрицательным.

ХОРОШО

Гипотеза из корреляции

«Предложение напоминания после первой тренировки повысит долю регулярных на 3 п.п.».

Проверяется A/B-тестом.

6.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Опрос по всей базе вместо точки сценария	Отвечают не те, отвечают по памяти	Опрос в момент события
Наводящие варианты ответа	Подтверждается ожидаемое	Нейтральные варианты и «другое»
Выводы о причинах из корреляций	Неверные решения	Эксперимент
Нет сравнения сегментов	Средний ответ скрывает различия	Разрез по сегментам

6.6 Смещения выборки

СМЕЩЕНИЕ	КАК ВОЗНИКАЕТ	КАК СНИЗИТЬ
Самоотбор	Отвечают самые вовлечённые или самые недовольные	Опрос в точке сценария, короткий
Выживших	Спрашиваем только тех, кто остался	Отдельно опрашивать ушедших
Социальной желательности	Человек отвечает, «как правильно»	Анонимность, вопросы о поведении
Порядка вариантов	Первый вариант выбирают чаще	Случайный порядок

В опросе «Формы» варианты показывались в случайном порядке, а отвечали 18% — для опроса в продукте это нормальная доля. Сравнение ответивших и неответивших по сегментам и источникам трафика не показало сильных различий, поэтому результатам можно было доверять.

ПРИМЕР

Онлайн-кинотеатр

Кинотеатр увидел, что зрители, добавившие фильм в «буду смотреть», уходят реже. Кнопку сделали заметнее, добавления выросли вдвое, отток не изменился. Связь объяснялась мотивацией: те, кто планирует смотреть, и так остаются. Эксперимент до раскатки сэкономил бы месяц.

6.7 Вопросы для самопроверки

- [ ] Почему 12 интервью не дают процентов?
- [ ] Сколько ответов нужно для погрешности ±3 п.п.?
- [ ] Чем опрос в точке сценария лучше рассылки по базе?
- [ ] Почему корреляцию нельзя превращать в решение без эксперимента?
- [ ] Какие смещения выборки встречаются чаще всего?

ПРАКТИКА 6 после главы 06

Проверьте главную находку интервью количественно.

ЧТО СДЕЛАТЬ

01	Сформулируйте вопрос, который измеряет распространённость находки.	☐
02	Выберите момент сценария для опроса в продукте.	☐
03	Посчитайте нужное число ответов по формуле (6.1).	☐
04	Разрежьте результаты по 2–3 сегментам.	☐
05	Найдите в данных поведения связь, которую стоит проверить экспериментом.	☐

РЕЗУЛЬТАТ Если находка встречается меньше чем у 10% сегмента, гипотеза на ней вряд ли сдвинет метрику.

07 Анализ конкурентов и рынка

После неё вы разбираете решения конкурентов как источник гипотез, а не образец для копирования, и сверяете свои метрики с рынком.

7.1 Что смотреть · 7.2 Кейс «Формы»: разбор пяти приложений · 7.3 Рынок и бенчмарки · 7.4 Анти-паттерны · 7.5 Вопросы для самопроверки

Конкуренты уже провели тысячи экспериментов, и результат многих виден снаружи: какой онбординг, какой экран оплаты, какие тарифы, что изменилось за год. Это бесплатный источник идей. Но копировать решения напрямую опасно: вы видите итог, но не знаете, сработал ли он, для кого и при каких условиях.

7.1 Что смотреть

Область	Что изучать	Источник
Онбординг	Число шагов, вопросы, момент первой ценности	Прохождение самому, записи экрана
Монетизация	Триал, цены, экран оплаты, предложения при отмене	Подписка и отмена в разных странах
Удержание	Напоминания, серии, челленджи, сообщество	Неделя использования, рассылки
Позиционирование	Описание в сторе, скриншоты, отзывы	Стор, сервисы аналитики сторов
Изменения во времени	Что поменялось за год	Архив версий описаний, обзоры

7.2 Кейс «Формы»: разбор пяти приложений

Ксения и Лера прошли онбординг и первую неделю в пяти конкурирующих приложениях и записали каждый экран. Сравнение по ключевым точкам заняло таблицу на две страницы. Главные наблюдения:

НАБЛЮДЕНИЕ	У СКОЛЬКИХ ИЗ 5	ГИПОТЕЗА ДЛЯ «ФОРМЫ»
Первая тренировка 7–10 минут без инвентаря	4	Короткая стартовая тренировка для «похудеть»
План недели сразу после анкеты	3	План с датами и напоминанием вместо «начать сейчас»
Годовой тариф по умолчанию на экране оплаты	4	Тест порядка тарифов
Напоминание за день до конца триала	2	Снизит возвраты и негатив в отзывах
Персональный тренер в чате	1	Не берём: дорого, нет данных об эффекте

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Копировать решение, потому что «у лидера рынка так». Лидер мог проверить его на другой аудитории, другой цене и другом трафике — или не проверять вовсе. Наблюдение у конкурента — повод для гипотезы, а не замена эксперимента.

7.3 Рынок и бенчмарки

Открытые отчёты по подписочным приложениям дают ориентиры по конверсии и удержанию в категории. Они помогают понять, где продукт явно отстаёт. В «Форме» сравнение показало, что конверсия триала в оплату на уровне рынка, а удержание на третьем месяце — на 5–8 п.п. ниже медианы категории. Это укрепило решение сделать отток главным рычагом.

ПЛОХО

Копия

«У них годовой тариф по умолчанию — делаем так же».

Релиз без теста; эффект неизвестен.

ХОРОШО

Гипотеза

«Если годовой тариф стоит первым, доля годовых вырастет с 28% до 35% без падения конверсии».

A/B-тест на экране оплаты.

7.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Смотреть только на лидера	Узкий взгляд	4–6 конкурентов разного размера
Разбор по скриншотам	Не видно сценария	Пройти путь самому
Копировать без проверки	Чужие решения на своей аудитории	Превращать в гипотезы
Разовый разбор	Пропуск изменений	Повтор раз в квартал

МИРОВОЙ КЕЙС Мобильные издатели, практика тестов страниц приложений

Тест в сторе до разработки

App Store и Google Play позволяют тестировать варианты скриншотов, иконок и описаний на части посетителей страницы. Многие издатели используют это как дешёвую проверку позиционирования до разработки функций.

Если сообщение «8 минут без инвентаря» поднимает конверсию страницы стора, это дополнительный сигнал в пользу соответствующей продуктовой гипотезы.

«Форма» провела такой тест параллельно с разбором конкурентов: вариант скриншотов с акцентом на короткие тренировки дал +9% к конверсии страницы в установку. Уверенность для Г-07 и М-04 поднялась с 50% до 80% по шкале из главы 9.

ПРИМЕР

Еда по подписке

Сервис наборов для готовки скопировал у конкурента скидку 50% на первый заказ. Регистрации выросли, но доля вторых заказов упала с 38% до 21%: скидка привлекла «охотников». Тест с меньшей скидкой и бесплатной доставкой второго заказа дал меньше регистраций, но больше постоянных клиентов.

7.5 Вопросы для самопроверки

- [ ] Почему нельзя копировать решения лидера рынка?
- [ ] Что стоит изучать у конкурентов, кроме интерфейса?

- Как превратить наблюдение у конкурента в гипотезу?
- Зачем повторять разбор раз в квартал?
- Какие бенчмарки полезны, а какие вводят в заблуждение?

ПРАКТИКА 7 после главы 07

Разберите 4–5 конкурентов в точках вашей воронки.

ЧТО СДЕЛАТЬ

01	Пройдите онбординг, первую неделю и оплату в каждом приложении.	☐
02	Запишите решения по точкам воронки в общую таблицу.	☐
03	Отметьте решения, которые встречаются у большинства.	☐
04	Превратите 3–5 наблюдений в гипотезы для своего продукта.	☐
05	Сравните свои ключевые метрики с открытыми бенчмарками.	☐

РЕЗУЛЬТАТ Повторяйте разбор раз в квартал: изменения у конкурентов — сигнал их выигравших экспериментов.

08 Структура гипотезы

После неё вы записываете гипотезу так, чтобы её можно было проверить и опровергнуть: изменение, аудитория, ожидаемый эффект в числах, причина и критерий успеха.

8.1 Шаблон · 8.2 Кейс «Формы»: гипотеза Г-07 · 8.3 Признаки хорошей гипотезы · 8.4 Анти-паттерны · 8.5 Дерево гипотез · 8.6 Вопросы для самопроверки

Идея — это «давайте сделаем короткую первую тренировку». Гипотеза — это проверяемое утверждение о том, что изменится, у кого, насколько и почему. Разница принципиальная: идею можно только реализовать, гипотезу можно подтвердить или опровергнуть. И после опровержения команда знает больше, чем до него.

8.1 Шаблон

```
Если мы  <изменение>
для      <аудитория, сегмент, точка сценария>,
то       <целевая метрика> изменится с <A> до <B>
потому что <причина: наблюдение из данных или исследования>.
Мы поймём, что ошиблись, если <критерий опровержения>,
и проверим, что не ухудшились <защитные метрики>.
```

8.2 Кейс «Формы»: гипотеза Г-07

```
Г-07 · короткая первая тренировка
Если мы  предложим первой тренировкой 8-минутную сессию без инвентаря
для      новых пользователей с целью «похудеть» после выбора программы,
то       доля начавших тренировку в 1-й день вырастет с 31% до 36%
потому что 33% сегмента в опросе назвали причиной «слишком сложно»,
           9 из 12 интервьюируемых испугались 35-минутной тренировки.
Ошиблись, если рост меньше 2 п.п. или доля второй тренировки за неделю упала.
Защитные: конверсия в триал, оценки первой тренировки.
```

8.3 Признаки хорошей гипотезы

Опровержимая	Есть результат, при котором мы признаем ошибку. «Пользователям станет удобнее» опровергнуть нельзя.
Конкретная	Одно изменение, одна аудитория, одна целевая метрика.
Обоснованная	Причина опирается на данные, интервью или поведение конкурентов, а не на вкус.
Связанная с целью	Целевая метрика — рычаг из дерева метрик.
С числом	Ожидаемый эффект задан — от него зависит размер выборки.

КЛАССИКА

Карл Поппер, «Логика научного открытия», 1934

Фальсифицируемость

Поппер предложил считать научной только ту теорию, которую можно опровергнуть опытом. Теория, совместимая с любым исходом, ничего не утверждает о мире.

Для продукта это значит: гипотеза, которая «подтвердится» при любом результате теста, — не гипотеза, а оправдание уже принятого решения.

ПЛОХО

Идея без проверки

«Сделаем онбординг лучше».

«Добавим челленджи — это повысит вовлечённость».

ХОРОШО

Проверяемая гипотеза

«Если показывать план на 7 дней после анкеты, доля со 2-й тренировкой за неделю вырастет с 52% до 56%, потому что 41% не начинают из-за неподходящего времени».

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Записывать в гипотезу решение, которое уже приняли, и подбирать метрику после теста. Если метрика выбирается по результатам, найдётся хоть одна, которая выросла. Целевая метрика и критерий опровержения фиксируются до запуска.

8.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Три изменения в одной гипотезе	Непонятно, что сработало	Одно изменение или явный пакет
Нет ожидаемого эффекта	Нельзя рассчитать выборку	Число «с — до»
Причина «мы так думаем»	Слабые гипотезы	Ссылка на данные или исследование
Метрика выбирается после теста	Ложные победы	Фиксировать до запуска

8.5 Дерево гипотез

Гипотезы удобно связывать с деревом метрик: каждая висит на конкретном рычаге, а рычаг — на ветке звезды. Тогда сразу видно, где гипотез много, а где ни одной.

```
Рычаг: тренировка в 1-й день (34% → 40%)
 Г-07 короткая первая тренировка для «похудеть»          RICE 41 600
 Т-02 предзагрузка видео во время онбординга            RICE 28 900
 Г-12 план на 7 дней вместо «начать сейчас»             RICE 34 080
Рычаг: отток платящих (11% → 9%)
 Г-18 серия недель с ≥2 тренировками и награда          RICE 22 400
 Г-24 пауза подписки вместо отмены                       RICE 18 700
Рычаг: триал → оплата (41% → 45%)
 Г-03 напоминание за день до конца триала              RICE 34 560
```

ПРИМЕР

Поиск жилья

Команда сервиса аренды записала: «Новый фильтр сделает поиск удобнее». После переписывания: «Если добавить фильтр «можно с животными», доля поисков с откликом у владельцев питомцев вырастет с 9% до 12%, потому что 18% обращений в поддержку — об этом». Вторую версию можно было проверить и опровергнуть.

8.6 Вопросы для самопроверки

- Чем идея отличается от гипотезы?
- Зачем гипотезе критерий опровержения?
- Почему в гипотезе одно изменение и одна целевая метрика?
- Откуда берётся причина в формулировке?
- Что не так с метрикой, выбранной после теста?

ПРАКТИКА 8 после главы 08

Перепишите три идеи из своего бэклога в проверяемые гипотезы.

ЧТО СДЕЛАТЬ

01	Возьмите три идеи из бэклога или из глав 4–7.	☐
02	Заполните шаблон для каждой: изменение, аудитория, метрика «с — до», причина.	☐
03	Добавьте критерий опровержения и защитные метрики.	☐
04	Проверьте каждую по пяти признакам.	☐

РЕЗУЛЬТАТ Если для идеи не находится причины из данных, ей нужно исследование, а не эксперимент.

09 Критерии приоритизации

После неё вы оцениваете гипотезы по влиянию, уверенности и стоимости с помощью ICE, RICE и PIE, понимаете их слабые места и выбираете фреймворк под свою команду.

9.1 Популярные фреймворки · 9.2 Шкала уверенности · 9.3 Кейс «Формы»: первый рейтинг · 9.4 Анти-паттерны · 9.5 Вопросы для самопроверки

Гипотез всегда больше, чем ёмкость команды. В «Форме» после исследований бэклог вырос до 58 гипотез, а провести за квартал можно 10–12 экспериментов. Без явных критериев выбор делается по громкости голоса: побеждает гипотеза того, кто старше или убедительнее. Фреймворки приоритизации не дают правильного ответа, но делают выбор прозрачным и сравнимым.

9.1 Популярные фреймворки

ФРЕЙМВОРК	ФОРМУЛА	СИЛЬНО	СЛАБО
ICE	Impact × Confidence × Ease, по 1–10	Быстро, понятно	Субъективные оценки
RICE	Reach × Impact × Confidence / Effort	Учитывает охват	Нужны данные по охвату
PIE	Potential × Importance × Ease	Для страниц и точек сценария	Не учитывает уверенность
Взвешенная матрица	Σ (вес × оценка)	Гибко под цели	Долго настраивать

ФОРМУЛА 9.1 · RICE

$$RICE = \frac{R \cdot I \cdot C}{E} \tag{9.1}$$

где

R — охват: пользователей в точке за месяц — чел.

I — влияние на целевую метрику: 0,25 / 0,5 / 1 / 2 / 3 — балл

C — уверенность: 50% / 80% / 100% — доля

E — трудозатраты — чел.-нед.

```
Г-07: R = 39 000 (сегмент «похудеть» после онбординга), I = 2, C = 80%, E = 1,5 → RICE = 39 000 · 2 · 0,8 / 1,5 = 41 600
```

9.2 Шкала уверенности

Самая полезная часть любого фреймворка — уверенность. Её стоит привязать к доказательствам, а не к ощущениям. В «Форме» договорились так:

УВЕРЕННОСТЬ	ОСНОВАНИЕ
100%	Похожий эксперимент уже выиграл в нашем продукте
80%	Количественные данные и качественные исследования совпадают
50%	Есть одно основание: интервью, опрос или решение конкурента
20%	Мнение или интуиция команды

9.3 Кейс «Формы»: первый рейтинг

ГИПОТЕЗА	R	I	C	E	RICE
Г-07 Короткая первая тренировка	39 000	2	0,8	1,5	41 600
Г-12 План на 7 дней после анкеты	85 200	1	0,8	2	34 080
Г-03 Напоминание за день до конца триала	21 600	1	0,8	0,5	34 560
Г-21 Челленджи с друзьями	64 000	2	0,2	6	4 270
Г-15 Годовой тариф первым	21 600	0,5	0,5	0,5	10 800

Челленджи с друзьями — любимая идея основателя — оказались внизу: огромные трудозатраты и уверенность на уровне мнения. Это не значит, что идею надо выбросить. Ей нужно дешёвое исследование, которое поднимет уверенность, прежде чем вкладывать шесть недель разработки.

ПЛОХО

Оценки по ощущениям

«Влияние — 8, уверенность — 9».

У каждого члена команды свои цифры.

ХОРОШО

Оценки по основаниям

Охват — из аналитики, уверенность — по шкале доказательств.

Две оценки расходятся — обсуждаем основания.

9.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Рейтинг как истина	Механический выбор	Рейтинг — повод для обсуждения
Оценивает один человек	Смещения автора	Независимые оценки 2–3 человек
Уверенность «из головы»	Сильные мнения побеждают	Шкала доказательств
Рейтинг не пересматривается	Новые данные не учитываются	Пересчёт после каждого теста

МИРОВОЙ КЕЙС Шон Эллис, GrowthHackers, 2010-е

ICE-скоринг

Шон Эллис популяризировал ICE как самый быстрый способ сравнить идеи в команде роста: оценить влияние, уверенность и простоту по шкале от 1 до 10.

Он же предупреждал, что ICE — инструмент для разговора, а не калькулятор решений: если оценки расходятся, обсуждение важнее среднего балла.

ПРИМЕР

Игровая студия

Студия оценивала идеи по ICE на планёрке вслух, и оценки подстраивались под мнение продюсера. Перешли на независимые оценки в таблице до встречи. Расхождения больше трёх баллов обсуждались отдельно — и в половине случаев выяснялось, что у кого-то есть данные, которых не видели остальные.

9.5 Вопросы для самопроверки

- Чем RICE отличается от ICE?
- Почему уверенность стоит привязать к доказательствам?
- Что делать, если оценки двух людей сильно расходятся?
- Почему рейтинг не должен механически определять выбор?
- Как поднять уверенность дорогой гипотезы, не делая её?

ПРАКТИКА 9 после главы 09

Посчитайте RICE для 10 гипотез из своего бэклога.

ЧТО СДЕЛАТЬ

01	Договоритесь о шкалах влияния и уверенности.	☐
02	Возьмите охват из аналитики, а не на глаз.	☐
03	Попросите двух коллег оценить независимо и сравните.	☐
04	Обсудите гипотезы, где оценки расходятся больше всего.	☐

РЕЗУЛЬТАТ Расхождение оценок часто ценнее самого рейтинга: оно показывает, где не хватает данных.

10 Продуктовые, маркетинговые и технические гипотезы

После неё вы различаете типы гипотез по тому, что меняется и где измеряется эффект, выбираете для каждого подходящий метод проверки и владельца.

10.1 Три типа
10.2 Кейс «Формы»: примеры по типам
10.3 Технические гипотезы тоже про продукт
10.4 Анти-паттерны
10.5 Календарь тестов
10.6 Вопросы для самопроверки

Гипотезы отличаются не только содержанием, но и тем, где они проверяются и кто за них отвечает. Изменение онбординга проверяется A/B-тестом в продукте; новый рекламный креатив — сплитом в рекламном кабинете; ускорение загрузки — техническим экспериментом с замером производительности. Смешивать их в одном бэклоге без разметки — значит сравнивать несравнимое.

10.1 Три типа

ТИП	ЧТО МЕНЯЕТСЯ	ГДЕ ЭФФЕКТ	КАК ПРОВЕРЯЮТ	ВЛАДЕЛЕЦ
Продуктовая	Функция, сценарий, интерфейс, цена	Поведение пользователей в продукте	A/B-тест, фича-флаг	Продакт
Маркетинговая	Канал, сообщение, креатив, аудитория	Привлечение: CTR, CPI, конверсия в установку	Сплит в рекламе, тесты страниц стора	Маркетинг
Техническая	Производительность, стабильность, инфраструктура	Скорость, ошибки, косвенно — конверсия	Канареечный релиз, A/B по версии	Техлид

10.2 Кейс «Формы»: примеры по типам

Продуктовая Г-07	Короткая первая тренировка для «похудеть» → тренировка в 1-й день 31% → 36%.
Маркетинговая М-04	Креатив «8 минут в день без инвентаря» вместо «Похудей к лету» → конверсия из клика в установку 22% → 26% и активация трафика выше.
Техническая Т-02	Предзагрузка видео первой тренировки во время онбординга → время до старта видео 6,2 с → 1,5 с, тренировка в 1-й день +1–2 п.п.

Интересно, что маркетинговая гипотеза М-04 выросла из той же находки, что и продуктовая Г-07: страх сложности. Если обещание в рекламе совпадает с первым опытом в продукте, эффекты складываются. Ксения договорилась с маркетингом проверять их последовательно: сначала продукт, затем креатив под новый первый опыт.

ПРАВИЛО

Маркетинговые изменения меняют состав аудитории. Если одновременно с продуктовым тестом запустить новый креатив, в обе группы теста придут другие люди, и результат будет относиться уже к новой смеси.

10.3 Технические гипотезы тоже про продукт

Технические гипотезы часто остаются вне продуктового бэклога, потому что их сложно оценить. Но скорость загрузки и стабильность напрямую влияют на конверсию. Т-02 проверили A/B-тестом по версии приложения: предзагрузка подняла долю начавших тренировку в первый день на 1,6 п.п. — больше, чем многие интерфейсные изменения.

ПЛОХО

Общий список

Креативы, онбординг и рефакторинг в одном рейтинге.

Технические задачи всегда внизу: «не про пользователя».

ХОРОШО

Разметка по типам

У каждого типа свой метод и владелец.

Технические гипотезы оцениваются по эффекту на ту же метрику.

10.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Маркетинговый и продуктовый тест одновременно на одном потоке	Смешение эффектов	Календарь тестов
Технические изменения без замера	Эффект не виден	Гипотеза с метрикой
Один метод для всех типов	Неточные результаты	Метод по типу

10.5 Календарь тестов

НЕДЕЛЯ	ОНБОРДИНГ	ЭКРАН ОПЛАТЫ	РЕКЛАМА	ТЕХНИКА
1–2	Г-07	Г-03	—	Т-02 канарейка 10%
3–4	Г-12	Г-15	М-04 после итогов Г-07	Т-02 A/B по версии
5–6	Г-12 продолжение	Г-09	М-06	—

Календарь показывает, какие тесты идут параллельно на разных точках, а какие должны ждать друг друга. Тесты на разных экранах можно вести одновременно, если они не влияют на одну целевую метрику напрямую; на одном экране — только последовательно или в общем многовариантном тесте.

ПРИМЕР

Электронная коммерция

Интернет-магазин считал ускорение загрузки каталога «технической задачей без бизнес-эффекта». A/B по версии сервера показал: ускорение на 0,8 с подняло конверсию в корзину на 1,9%. После этого технические гипотезы получили место в общем бэклоге.

10.6 Вопросы для самопроверки

- [ ] Чем продуктовая гипотеза отличается от маркетинговой по месту эффекта?
- [ ] Почему маркетинговый тест может испортить продуктовый?

- Как оценить техническую гипотезу по продуктовой метрике?
- Зачем общий календарь тестов?
- Когда пара гипотез разных типов сильнее каждой?

ПРАКТИКА 10 после главы 10

Разметьте свой бэклог гипотез по типам.

ЧТО СДЕЛАТЬ

01	Присвойте каждой гипотезе тип: продуктовая, маркетинговая, техническая.	☐
02	Назначьте владельца и метод проверки для каждой.	☐
03	Найдите пары гипотез разных типов, которые опираются на одну находку.	☐
04	Составьте календарь, чтобы тесты на одном потоке не пересекались.	☐

РЕЗУЛЬТАТ Пара «продукт + маркетинг» на одной находке часто даёт больше, чем каждая гипотеза по отдельности.

11 Оценка влияния на ключевые метрики

После неё вы оцениваете ожидаемый эффект гипотезы в числах — от рычага до выручки, — учитываете охват и долю затронутых пользователей и не завышаете эффект на порядок.

11.1 От эффекта на шаге к деньгам · 11.2 Откуда брать ожидаемый эффект · 11.3 Кейс «Формы»: проверка реализма · 11.4 Бенчмарки · 11.5 Анти-паттерны · 11.6 Кейс «Формы»: оценки до и после калибровки · 11.7 Вопросы для самопроверки

Оценка влияния — самое неточное место приоритизации. Команда легко верит, что новая функция поднимет конверсию на 20%, хотя типичный выигрышный эксперимент даёт 2–5% относительного роста. Завышенные ожидания приводят к двум бедам: выбору не тех гипотез и тестам с недостаточной выборкой, которые не могут увидеть реальный, меньший эффект.

11.1 От эффекта на шаге к деньгам

ФОРМУЛА 11.1 · ОЖИДАЕМЫЙ ВКЛАД ГИПОТЕЗЫ В ВЫРУЧКУ

$$\Delta MRR \approx R \cdot s \cdot \Delta c \cdot k \cdot ARPPU \tag{11.1}$$

где

R	—	пользователей в точке теста в месяц	чел.
s	—	доля затронутых изменением	доля
Δc	—	абсолютный рост конверсии шага	п.п.
k	—	конверсия от этого шага до оплаты	доля

```
Г-07: R = 39 000, s = 1, Δc = 5 п.п., k = 0,22 (от первой тренировки до оплаты у «похудеть») → +429 платящих в месяц → +223 тыс. ₽ MRR в первый месяц
```

Месячный прирост кажется скромным, но он накапливается: каждый месяц приходит на 429 платящих больше, и при оттоке 11% база в равновесии вырастет на 429 / 0,11 ≈ 3 900

человек, то есть примерно на 2 млн ₽ MRR. Так оценка превращается в язык цели из главы 1.

11.2 Откуда брать ожидаемый эффект

ИСТОЧНИК	ЧТО ДАЁТ	ПРИМЕР
История своих экспериментов	Распределение эффектов похожих изменений	Тесты онбординга: медиана +1,8 п.п.
Размер проблемы	Верхняя граница: эффект не больше доли затронутых	33% сегмента боятся сложности → максимум +10 п.п.
Бенчмарки	Где продукт отстаёт от рынка	Удержание M3 ниже медианы на 6 п.п.
Опрос намерений	Очень оптимистичная оценка, делить на 3–5	«Начал бы короткую тренировку» — 60%

11.3 Кейс «Формы»: проверка реализма

Первая оценка Г-07 от дизайнера была «+15 п.п.»: ведь треть сегмента назвала причиной сложность. Артур разобрал её по шагам. Даже если все 33% испугавшихся начнут тренировку, они составляют треть от 69% не начавших, то есть ~23% сегмента. Часть из них не начнёт по другим причинам, часть уйдёт на второй тренировке. Реалистичный диапазон — 3–6 п.п.; в гипотезу записали 5.

ПРАВИЛО

Верхняя граница эффекта — доля пользователей, у которых есть проблема, которую решает изменение. Если оценка выше этой доли, она заведомо завышена.

МИРОВОЙ КЕЙС Рон Кохави и др., «Trustworthy Online Controlled Experiments», 2020

Большинство идей не работает

Кохави, руководивший экспериментами в Microsoft, приводит данные: в Bing и других продуктах лишь около трети экспериментов улучшают целевые метрики, треть нейтральны, треть ухудшают. В зрелых продуктах доля успехов ещё ниже.

Отсюда вывод: оценки влияния нужно делать скромными, а систему экспериментов — дешёвой, чтобы проверять много идей.

ПЛОХО

Оптимистичная оценка

«Конверсия вырастет на 20%».

Тест на 1 000 человек — результат «незначимый».

ХОРОШО

Реалистичная оценка

«+3–6 п.п., ожидаем 5; верхняя граница — 23% сегмента».

Выборка рассчитана под 3 п.п.

11.4 Бенчмарки

ТИП ИЗМЕНЕНИЯ	ТИПИЧНЫЙ ОТНОСИТЕЛЬНЫЙ ЭФФЕКТ ВЫИГРЫШНОГО ТЕСТА
Тексты и мелкие правки интерфейса	0,5–3%
Новый шаг или экран в сценарии	2–8%
Изменение цены и тарифной сетки	5–20% по выручке, часто с падением конверсии
Новая крупная функция	сильно варьирует, часто около нуля

11.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Эффект «на глаз»	Неверные приоритеты	Формула (11.1) и источники
Не учитывать долю затронутых	Завышение в разы	Множитель s
Опрос намерений как эффект	Оценка в 3–5 раз выше реальной	Делить и сверять с историей
Нет связи с выручкой	Нельзя сравнить гипотезы разных шагов	Переводить в рубли

11.6 Кейс «Формы»: оценки до и после калибровки

ГИПОТЕЗА	ПЕРВАЯ ОЦЕНКА	ПОСЛЕ ПРОВЕРКИ	ФАКТ
Г-07 Короткая первая тренировка	+15 п.п.	+5 п.п.	+4,6 п.п.

ГИПОТЕЗА	ПЕРВАЯ ОЦЕНКА	ПОСЛЕ ПРОВЕРКИ	ФАКТ
Г-12 План на 7 дней	+8 п.п.	+4 п.п.	+1,2 п.п. (вариант с датами +2,6)
Г-03 Напоминание до конца триала	+5 п.п.	+3 п.п.	+2,4 п.п. по оплате, −0,9 п.п. возвратов
Г-15 Годовой тариф первым	+12 п.п. доли годовых	+6 п.п.	+5 п.п. (DiD)

Первые оценки команды оказались выше факта в 2–4 раза, оценки после проверки по верхней границе и истории — близки к факту. Разница между ними и есть ценность этапа оценки: она спасает от тестов, которые заведомо не наберут нужную выборку.

ПРИМЕР

Тревел

Сервис бронирования ожидал от нового календаря цен +10% к бронированиям. Расчёт по доле пользователей, меняющих даты, показал верхнюю границу +3%. Тест рассчитали на MDE 1,5% и увидели +1,7% — эффект, который потерялся бы в тесте под исходные ожидания.

11.7 Вопросы для самопроверки

- Какова верхняя граница эффекта гипотезы?
- Почему ответы в опросе о намерениях нужно делить?
- Как перевести эффект шага воронки в выручку?
- Какой эффект типичен для выигрышного теста интерфейса?
- Чем опасна завышенная оценка, кроме неверного приоритета?

ПРАКТИКА 11 после главы 11

Оцените ожидаемый эффект пяти верхних гипотез.

ЧТО СДЕЛАТЬ

01	Для каждой определите охват, долю затронутых и конверсию до оплаты.	☐
02	Найдите верхнюю границу эффекта по размеру проблемы.	☐
03	Сверьте с историей своих экспериментов или бенчмарками.	☐
04	Переведите эффект в прирост MRR по формуле (11.1).	☐

РЕЗУЛЬТАТ Если оценки после проверки упали в 2–3 раза — это нормально и полезно.

12 Оценка сложности и стоимости реализации

После неё вы оцениваете стоимость гипотезы целиком — разработку, дизайн, аналитику, время теста и риск, — и ищете самый дешёвый способ её проверить.

12.1 Из чего складывается стоимость
12.2 Минимальная проверка
12.3 Кейс «Формы»: челленджи за 3 дня вместо 6 недель
12.4 Анти-паттерны
12.5 Бенчмарки
12.6 Вопросы для самопроверки

Стоимость гипотезы — это не только часы разработки. Сюда входят дизайн и тексты, настройка аналитики, время самого теста, в течение которого точка занята, и стоимость риска, если вариант окажется вредным. Гипотеза за неделю разработки, которая занимает экран оплаты на месяц, может стоить дороже, чем гипотеза за три недели на экране с большим трафиком.

12.1 Из чего складывается стоимость

СОСТАВЛЯЮЩАЯ	КАК ОЦЕНИТЬ	Г-07
Разработка	чел.-дни на минимальную версию для теста	4 дня: новая тренировка + ветка онбординга
Дизайн и контент	Макеты, видео, тексты	Съёмка 8-минутной тренировки, 3 дня
Аналитика	События, дашборд, расчёт	1 день
Время точки	Недели трафика, когда другие тесты здесь невозможны	2 недели онбординга
Риск	Возможный ущерб × вероятность	Низкий: защитные метрики, откат флагом

12.2 Минимальная проверка

Для теста не нужно делать функцию полностью. Нужно сделать ровно столько, чтобы

пользователь получил изменённый опыт и мы измерили эффект. Всё остальное — масштабируемость, админка, локализация, крайние случаи — делается после победы.

Фейковая дверь	Кнопка или пункт меню ведут на экран «скоро будет» с опросом. Измеряет спрос, а не эффект.
Волшебник страны Оз	Функция выглядит автоматической, а внутри работает человек. Подходит для персональных планов и подборок.
Ручная версия	Контент или настройки для тестовой группы готовятся вручную.
Ограниченная аудитория	Только одна платформа, одна страна, один сегмент.

12.3 Кейс «Формы»: челленджи за 3 дня вместо 6 недель

Гипотеза Г-21 «челленджи с друзьями» требовала 6 недель: приглашения, лента, синхронизация прогресса. Ксения предложила проверить спрос дешевле. На экране после второй тренировки 10% пользователей видели кнопку «Позвать друга в челлендж». Нажатие открывало экран «Функция в разработке, хотите узнать первым?».

РЕЗУЛЬТАТ ФЕЙКОВОЙ ДВЕРИ

1. **Показы**
   9 400 пользователей за две недели.
2. **Нажатия**
   3,1% нажали кнопку; 1,2% оставили контакт.
3. **Сравнение**
   Похожая кнопка «Поделиться результатом» — 7,8% нажатий.
4. ✓ **Решение**
   Спрос низкий; Г-21 отложена, уверенность снижена до 20%. Сэкономлено 6 недель разработки.

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Делать «нормально, чтобы потом не переделывать». Две трети гипотез не подтверждаются, и тщательно сделанная функция чаще всего удаляется после теста. Делайте минимум для проверки и закладывайте доработку после победы отдельной задачей.

МИРОВОЙ КЕЙС — Ник Суинмерн, Zappos, 1999

Фейковая дверь у Zappos

Основатель Zappos проверял, будут ли люди покупать обувь онлайн, не закупая товар: он фотографировал обувь в местных магазинах, выкладывал на сайт и при заказе покупал пару в магазине сам.

Это классический пример проверки спроса без построения бизнеса: дорогую часть заменили ручной работой до того, как стало ясно, что идея работает.

ПЛОХО

Полная реализация

6 недель на челленджи с лентой и синхронизацией.

После теста функцию удаляют.

ХОРОШО

Минимальная проверка

3 дня на фейковую дверь.

Спрос измерен, решение принято за две недели.

12.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Стоимость = часы разработки	Недооценка времени точки и аналитики	Пять составляющих
Готовая функция до теста	Дорогие провалы	Минимальная версия
Фейковая дверь как доказательство эффекта	Спрос ≠ влияние на метрику	Дверь — для спроса, A/B — для эффекта

12.5 Бенчмарки

ЧТО	ОРИЕНТИР	«ФОРМА»
Доля гипотез, проверенных без полной разработки	30–50%	41% к концу года
Средние трудозатраты на тест	3–10 чел.-дней	6 → 4 чел.-дня
Доля кода экспериментов, удалённого после теста	50–70%	62%

Почти две трети экспериментального кода удаляется — это нормальная цена знания. Поэтому каждый лишний день, вложенный в «качество» тестового варианта, чаще всего выбрасывается вместе с ним.

ПРИМЕР

Стоимость часа точки

Экран оплаты «Формы» пропускает 5 000 стартов триала в неделю. Если тест на нём занимает три недели вместо двух из-за слабого MDE, команда теряет треть квартальной ёмкости точки — около двух тестов.

ПРИМЕР

Сервис подбора тренеров

Платформа хотела сделать автоматический подбор тренера по анкете — 2 месяца разработки. Вместо этого месяц подбор делал менеджер вручную для 10% новых клиентов. Конверсия в первую оплату выросла с 22% до 31%, и только после этого алгоритм пошёл в разработку.

12.6 Вопросы для самопроверки

- [ ] Из чего складывается стоимость эксперимента?
- [ ] Что такое минимальная проверка?
- [ ] Чем фейковая дверь отличается от A/B-теста по тому, что измеряет?
- [ ] Почему «сделать нормально сразу» — ошибка?
- [ ] Как время точки влияет на стоимость?

ПРАКТИКА 12 после главы 12

Найдите дешёвый способ проверки для самой дорогой гипотезы бэклога.

ЧТО СДЕЛАТЬ

01	Оцените пять составляющих стоимости для трёх верхних гипотез.	☐
02	Для самой дорогой придумайте минимальную проверку: фейковая дверь, ручная версия, ограниченная аудитория.	☐
03	Сравните стоимость полной и минимальной проверки.	☐
04	Пересчитайте RICE с новой оценкой трудозатрат.	☐

РЕЗУЛЬТАТ Хорошая минимальная проверка стоит в 5–10 раз меньше полной реализации.

13 Формирование тестового бэклога

После неё вы ведёте бэклог гипотез как живой инструмент: со статусами, карточками, связью с рычагами, ёмкостью точек и регулярным пересмотром.

13.1 Статусы · 13.2 Карточка гипотезы · 13.3 Кейс «Формы»: бэклог на квартал · 13.4 Баланс портфеля · 13.5 Анти-паттерны · 13.6 Ритм работы с бэклогом · 13.7 Вопросы для самопроверки

Тестовый бэклог — это не список идей в чате, а упорядоченный набор гипотез, готовых к проверке. Каждая гипотеза в нём имеет карточку, статус, владельца и оценки. Бэклог отвечает на три вопроса: что тестируем сейчас, что следующее и почему именно это.

13.1 Статусы

СТАТУС	ЧТО ЗНАЧИТ	КРИТЕРИЙ ПЕРЕХОДА
Идея	Сырая мысль	Есть автор и связь с рычагом
Гипотеза	Заполнен шаблон из главы 8	Есть причина и ожидаемый эффект
Оценена	Посчитан RICE, выбран метод	Согласовано на приоритизации
Готова к тесту	Есть дизайн эксперимента и выборка	План из главы 17
В тесте	Идёт эксперимент	Набрана выборка
Решение	Запускаем / дорабатываем / отказываемся	Запись в базе знаний

13.2 Карточка гипотезы

```
Г-12 · План на 7 дней вместо «начать сейчас»
Рычаг:        2-я тренировка за неделю (52% → 56%) → отток
Тип:          продуктовая · владелец: Ксения · аналитик: Артур
Основания:    опрос — 41% «неподходящее время»; 3 из 5 конкурентов
Оценки:       R 85 200 · I 1 · C 0,8 · E 2 → RICE 34 080
Метод:        A/B, 50/50, все новые пользователи после анкеты
Точка:        онбординг · ёмкость: свободна с недели 3
Статус:       готова к тесту · связанные: Г-07, Т-02
```

13.3 Кейс «Формы»: бэклог на квартал

КАК СОБРАЛИ ПЕРВЫЙ КВАРТАЛ

1 Сбор
58 идей из метрик, интервью, опроса, конкурентов и команды.

2 Отсев
19 без связи с тремя рычагами — в «когда-нибудь»; 11 объединены как дубли.

3 Оценка
28 гипотез с RICE и минимальной проверкой.

4 Ёмкость
Расставлены по точкам с учётом ёмкости из главы 3.

✓ Итог
11 тестов на квартал: 5 онбординг, 3 экран оплаты, 2 удержание, 1 технический.

ПРАВИЛО

Бэклог пересматривается после каждого завершённого теста. Результат меняет уверенность в похожих гипотезах: проигрыш короткой тренировки снизил бы уверенность во всех гипотезах о «страхе сложности».

13.4 Баланс портфеля

Если брать только гипотезы с наибольшим RICE, бэклог заполняется мелкими безопасными изменениями. Ксения ввела правило портфеля: в квартал не меньше 20% тестов — смелые гипотезы с низкой уверенностью и большим потенциалом. Они чаще проигрывают, но именно из них приходят крупные выигрыши.

МИРОВОЙ КЕЙС Эрик Шмидт и Джонатан Розенберг, «How Google Works», 2014

Портфель 70/20/10

Google, по словам авторов, распределял ресурсы так: 70% — на основной бизнес, 20% — на смежные возможности, 10% — на радикальные идеи.

Для бэклога гипотез та же логика защищает от двух крайностей: только мелких оптимизаций и только рискованных ставок.

ПЛОХО

Список в чате

«Закинул идею в канал #ideas».

200 сообщений, ни одной оценки.

ХОРОШО

Бэклог с карточками

Статус, рычаг, оценки, метод, точка.

Ясно, что тестируем следующим и почему.

13.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Бэклог без статусов	Непонятно, что готово	Шесть статусов
Только безопасные гипотезы	Нет крупных выигрышей	Портфель с 20% смелых
Не пересматривать после тестов	Устаревшие оценки	Пересмотр после каждого решения
Нет ёмкости точек	Очередь на один экран	Расстановка по точкам

13.6 Ритм работы с бэклогом

ВСТРЕЧА	ЧАСТОТА	ДЛИТЕЛЬНОСТЬ	РЕЗУЛЬТАТ
Разбор новых идей	раз в неделю	30 мин	идеи → гипотезы или отказ

ВСТРЕЧА	ЧАСТОТА	ДЛИТЕЛЬНОСТЬ	РЕЗУЛЬТАТ
Приоритизация	раз в 2 недели	60 мин	обновлённый RICE, следующие 3–4 теста
Решения по тестам	по факту окончания	30 мин	решение и обновление бэклога
Квартальный план	раз в квартал	2 ч	портфель, ёмкость, цели рычагов

Ритм важнее инструмента. Бэклог «Формы» живёт в обычной таблице с фильтрами, но встречи проходят регулярно, и ни одна гипотеза не висит в статусе «идея» дольше двух недель.

ПРИМЕР

Продукт для малого бизнеса

Команда кассового приложения держала 300 идей в трекере. После чистки по связи с целью осталось 40, после объединения дублей — 26. Квартальный план поместился на одну страницу, и впервые за год все тесты квартала были запущены.

13.7 Вопросы для самопроверки

- Какие статусы нужны бэклогу гипотез?
- Что должно быть в карточке гипотезы?
- Зачем пересматривать бэклог после каждого теста?
- Почему нужен портфель со смелыми гипотезами?
- Как понять, что бэклог разросся?

ПРАКТИКА 13 после главы 13

Соберите тестовый бэклог на квартал.

ЧТО СДЕЛАТЬ

01	Заведите карточки для всех гипотез со статусами.	☐
02	Отсейте идеи без связи с рычагами цели.	☐
03	Расставьте оценённые гипотезы по точкам с учётом ёмкости.	☐
04	Проверьте баланс: есть ли 20% смелых гипотез.	☐
05	Назначьте дату пересмотра после первого завершённого теста.	☐

РЕЗУЛЬТАТ Бэклог на квартал помещается на одну страницу; если не помещается — гипотез слишком много.

14 Определение метода тестирования

После неё вы выбираете метод проверки под гипотезу — A/B, многовариантный тест, последовательный запуск, квазиэксперимент, прототип — и понимаете, какую уверенность даёт каждый.

14.1 Методы · 14.2 Когда нельзя делить пользователей · 14.3 Кейс «Формы»: метод под каждую гипотезу · 14.4 Анти-паттерны · 14.5 Бенчмарки · 14.6 Вопросы для самопроверки

A/B-тест — золотой стандарт, но не единственный способ проверить гипотезу. Он требует трафика, инструмента сплита и времени. Иногда гипотезу честнее проверить прототипом за три дня, иногда — последовательным запуском в одном регионе, а иногда без эксперимента вообще не обойтись. Выбор метода — это выбор между скоростью и уверенностью.

14.1 Методы

МЕТОД	КАК РАБОТАЕТ	УВЕРЕННОСТЬ	КОГДА
A/B-тест	Случайное деление пользователей на группы	высокая	Достаточно трафика, есть сплит
A/B/n и многовариантный	Несколько вариантов или комбинаций факторов	высокая, нужно больше трафика	Выбор из нескольких решений
Последовательный запуск (до/после)	Сравнение периодов	низкая	Нет сплита; сильный эффект
Квазиэксперимент	Сравнение регионов или платформ с похожей динамикой (разность разностей)	средняя	Нельзя рандомизировать по пользователям
Прототип и юзабилити-тест	Проверка понимания и сценария	о сценарии, не о метрике	Ранняя стадия, дорогая реализация

МЕТОД	КАК РАБОТАЕТ	УВЕРЕННОСТЬ	КОГДА
Фейковая дверь	Измерение спроса	о спросе	Новая функция

14.2 Когда нельзя делить пользователей

Некоторые изменения нельзя показать половине пользователей: цена в сторе одна для страны, рекламная кампания видна всем, а изменение рекомендательного алгоритма влияет на всех через общий контент. Тогда используют деление по кластерам — странам, городам, дням — и метод разности разностей: сравнивают изменение метрики в тестовом кластере с изменением в контрольном за тот же период.

ФОРМУЛА 14.1 · РАЗНОСТЬ РАЗНОСТЕЙ

$$DiD = (Y_{\text{Т,после}} - Y_{\text{Т,до}}) - (Y_{\text{С,после}} - Y_{\text{С,до}}) \tag{14.1}$$

где

$Y_{\text{Т}}$ — метрика в тестовом кластере –

$Y_{\text{С}}$ — метрика в контрольном кластере –

```
Тест годового тарифа в Казахстане (Т) против Беларуси (С): доля годовых Т 27% → 34%, С 26% → 28% → DiD = 7 - 2 = 5 п.п.
```

14.3 Кейс «Формы»: метод под каждую гипотезу

ГИПОТЕЗА	МЕТОД	ПОЧЕМУ
Г-07 Короткая первая тренировка	A/B 50/50	Трафик большой, сплит по пользователю возможен
Г-12 План на 7 дней	A/B/n: 3 варианта плана	Выбор из нескольких решений
Г-15 Годовой тариф первым	Квазиэксперимент по странам	Экран оплаты в сторе, нельзя показать двум группам
Г-21 Челленджи	Фейковая дверь	Сначала проверить спрос
Г-24 Пауза вместо отмены	Прототип + A/B	Сначала понять, понимают ли пауза

ПРАВИЛО

Выбирайте метод с наибольшей уверенностью, который вы можете себе позволить. Если A/B возможен — делайте A/B. Сравнение «до и после» оставляйте для случаев, когда другого нет, и записывайте риск сезонности в карточку.

МИРОВОЙ КЕЙС Google, 2009; рассказ Марисы Майер

41 оттенок синего

Google тестировал 41 оттенок синего для ссылок в рекламе, чтобы выбрать цвет с наибольшей кликабельностью. По рассказам, выбранный оттенок принёс компании заметный дополнительный доход.

История показывает возможности A/B/n при огромном трафике — и одновременно, почему так не стоит делать продукту с тысячами пользователей: каждый вариант требует своей выборки.

ПЛОХО

До и после без контроля

«Запустили новый экран оплаты в марте — конверсия выросла на 4 п.п.».

В марте вырос сезонный трафик мотивированных.

ХОРОШО

Контроль за тот же период

A/B или разность разностей со странами-контролем.

Сезонность вычитается.

14.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
A/B на всё	Тесты без трафика и смысла	Метод по гипотезе
До/после как доказательство	Сезонность и внешние события	Контрольный кластер
Многовариантный при малом трафике	Нет результата ни по одному варианту	2–3 варианта максимум

14.5 Бенчмарки

МЕТОД	ДОЛЯ В ПОРТФЕЛЕ «ФОРМЫ»	ТИПИЧНОЕ ВРЕМЯ ДО РЕШЕНИЯ
A/B и A/B/n	70%	2–4 недели

МЕТОД	ДОЛЯ В ПОРТФЕЛЕ «ФОРМЫ»	ТИПИЧНОЕ ВРЕМЯ ДО РЕШЕНИЯ
Квазиэксперимент по странам	9%	4–6 недель
Фейковая дверь	11%	1–2 недели
Прототип и юзабилити	10%	3–5 дней

Большинство решений «Формы» принимается A/B-тестом, но каждая третья гипотеза проверяется другим способом — быстрее или там, где сплит невозможен.

ПРИМЕР

Последовательный запуск

Когда стор не позволил тестировать цену на половине пользователей, «Форма» сменила цену годового тарифа сначала в одной стране, а соседнюю оставила контролем. Разность разностей за 4 недели показала рост выручки на пользователя на 6% при падении конверсии на 1,1 п.п.

ПРИМЕР

Такси

Сервис такси не мог делить пассажиров на группы для теста новой схемы распределения заказов: водители обслуживают всех. Тест провели по чередованию часов в нескольких городах, сравнивая с похожими городами-контролями. Схема сократила время подачи на 9% при росте заработка водителей.

14.6 Вопросы для самопроверки

- [ ] Когда A/B невозможен и что делать вместо него?
- [ ] Как работает разность разностей?
- [ ] Почему сравнение «до и после» ненадёжно?
- [ ] Чем многовариантный тест опасен при малом трафике?
- [ ] Какую уверенность дают прототип и фейковая дверь?

ПРАКТИКА 14 после главы 14

Выберите метод для пяти гипотез из бэклога.

ЧТО СДЕЛАТЬ

01	Для каждой проверьте: можно ли делить по пользователю, хватает ли трафика.	☐
02	Выберите метод с наибольшей доступной уверенностью.	☐
03	Для изменений, которые нельзя делить, подберите контрольный кластер.	☐
04	Запишите метод и его ограничения в карточку.	☐

РЕЗУЛЬТАТ Если для гипотезы подходит только «до/после», подумайте, нельзя ли сделать эффект сильнее.

15 Выбор аудитории и сегментов

После неё вы определяете, кто попадает в эксперимент, на каком шаге пользователь входит в тест, как делить группы и когда тестировать на сегменте, а не на всех.

15.1 Точка входа в тест
15.2 Единица рандомизации
15.3 Кейс «Формы»: тест на сегменте
15.4 Анти-паттерны
15.5 Кейс «Формы»: анализ по сегментам Э-14
15.6 Вопросы для самопроверки

Аудитория эксперимента — это пользователи, которых изменение реально касается. Если включить в тест всех, а изменение видят только 30%, эффект размоется в три раза, и для его обнаружения понадобится в девять раз больше выборки. Поэтому правило простое: в тест попадают только те, кто дошёл до точки изменения.

15.1 Точка входа в тест

Пользователь назначается в группу в момент, когда впервые может увидеть разницу между вариантами. Для Г-07 это экран после выбора программы у пользователей с целью «похудеть». Те, кто не дошёл до этого экрана, в анализ не попадают ни в одной группе.

ФОРМУЛА 15.1 · РАЗМЫВАНИЕ ЭФФЕКТА

$$\Delta c_{\text{все}} = s \cdot \Delta c_{\text{затронутые}},\ n_{\text{все}} \approx \frac{n}{s^2} \qquad (15.1)$$

где

s — доля участников теста, которые видят изменение — доля

n — нужная выборка при анализе только затронутых — чел.

```
Если анализировать Г-07 по всем установкам (s = 0,33), нужно в 1/0,33² ≈ 9 раз больше пользователей
```

15.2 Единица рандомизации

Пользователь	Стандарт для продуктовых тестов: один человек всегда видит один вариант на всех устройствах.
Устройство	Когда нет авторизации до точки теста; риск — один человек на двух устройствах в разных группах.
Сессия	Только для изменений без памяти: ранжирование поиска, порядок блоков.
Кластер	Город, страна, команда: когда пользователи влияют друг на друга.

15.3 Кейс «Формы»: тест на сегменте

Г-07 сформулирована для сегмента «похудеть», и Ксения сначала хотела тестировать только на нём. Артур предложил другой вариант: тестировать на всех новых пользователях после выбора программы, но заранее объявить сегмент «похудеть» главным, а остальные — исследовательскими. Так в одном тесте проверяется и основная гипотеза, и вопрос, не помогает ли короткая тренировка другим сегментам.

РЕШЕНИЕ	ЗА	ПРОТИВ
Только «похудеть»	Чистая проверка гипотезы	Нет данных по другим сегментам
Все, главный сегмент объявлен заранее	Больше знаний за тот же тест	Нужна поправка на множественные сравнения в остальных
Все без выделения сегмента	Просто	Эффект размыт, сегменты ищутся после — риск ложных находок

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Искать сегменты с эффектом после теста: «в целом не выросло, но у женщин 25–34 на Android выросло на 8%». При двадцати разрезах один почти наверняка покажет «значимый» эффект случайно. Сегменты для анализа объявляются до запуска.

МИРОВОЙ КЕЙС LinkedIn, исследования команды экспериментов, 2010-е

Тесты в соцсетях и сетевой эффект

LinkedIn описывал, что при тестировании функций, связанных с лентой и сообщениями, обычное деление по пользователям даёт искажённые результаты: пользователи из разных групп общаются и влияют друг на друга.

Решение — рандомизация по кластерам связанных пользователей, хотя она требует гораздо больше трафика.

ПЛОХО

Все установки в тесте

Деление в момент установки.

Две трети участников не дошли до изменения.

ХОРОШО

Деление в точке изменения

Назначение после выбора программы.

В анализе только те, кто мог увидеть разницу.

15.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Деление раньше точки изменения	Размывание эффекта	Назначение в точке
Сегменты после теста	Ложные находки	Объявить до запуска
Деление по устройству при авторизации	Один человек в двух группах	По пользователю
Пересекающиеся тесты на одной точке	Взаимное влияние	Слои и взаимоисключение

15.5 Кейс «Формы»: анализ по сегментам Э-14

СЕГМЕНТ	СТАТУС	n НА ГРУППУ	Δ	ИНТЕРВАЛ (α С ПОПРАВКОЙ)
«Похудеть»	главный	5 090	+4,6 п.п.	2,8…6,4
«Сила»	исследовательский	2 430	+0,4 п.п.	-3,1…3,9
«Гибкость»	исследовательский	2 100	+1,1 п.п.	-2,6…4,8
Без цели	исследовательский	1 440	+2,3 п.п.	-1,9…6,5

Для исследовательских сегментов интервалы посчитаны с поправкой Бонферрони на три сравнения, поэтому они шире. Сегмент «без цели» показал интересный, но недоказанный рост — его записали отдельной гипотезой Г-33, а не объявили победой.

ПРИМЕР

Социальная сеть

Тест новой ленты делил пользователей случайно, но друзья из разных групп видели разные посты и обсуждали их. Эффект на вовлечённость оказался завышен вдвое. Повторный тест по кластерам связанных пользователей показал реалистичный результат.

15.6 Вопросы для самопроверки

- В какой момент пользователь должен попадать в тест?
- Во сколько раз растёт выборка, если изменение видят 30% участников?
- Когда делить по устройству, а когда по пользователю?
- Почему сегменты объявляют до запуска?
- Что делать, если пользователи влияют друг на друга?

ПРАКТИКА 15 после главы 15

Определите аудиторию и точку входа для ближайшего теста.

ЧТО СДЕЛАТЬ

01	Найдите экран или событие, где пользователь впервые видит разницу.	☐
02	Посчитайте долю участников, которых изменение реально касается.	☐
03	Выберите единицу рандомизации.	☐
04	Объявите главный сегмент и исследовательские до запуска.	☐

РЕЗУЛЬТАТ Запишите аудиторию и сегменты в план эксперимента — к ним вы вернётесь при анализе.

16 Выбор длительности теста

После неё вы рассчитываете размер выборки по базовой конверсии, минимальному эффекту, значимости и мощности, переводите его в недели и не останавливаете тест раньше времени.

16.1 Четыре входа расчёта
16.2 От выборки к неделям
16.3 Подглядывание
16.4 Анти-паттерны
16.5 Бенчмарки
16.6 Вопросы для самопроверки

Длительность теста определяется не ощущением «вроде набралось», а расчётом до запуска. Нужно знать, сколько пользователей потребуется, чтобы заметить интересующий эффект с заданной надёжностью, и сколько недель трафика это займёт. Тест, остановленный раньше, даёт случайные результаты; тест, который идёт слишком долго, занимает точку и тормозит бэклог.

16.1 Четыре входа расчёта

Базовая конверсия p	Текущее значение целевой метрики: триал → оплата 41%.
Минимальный обнаруживаемый эффект (MDE)	Самый маленький эффект, ради которого стоит запускать: 3 п.п.
Уровень значимости α	Допустимая вероятность увидеть эффект, которого нет: обычно 5%.
Мощность 1 − β	Вероятность увидеть эффект, если он есть: обычно 80%.

ФОРМУЛА 16.1 · РАЗМЕР ГРУППЫ ДЛЯ ДОЛИ

$$n \approx \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \cdot 2p(1-p)}{\delta^2} \approx \frac{16 \cdot p(1-p)}{\delta^2} \qquad (16.1)$$

где

p — базовая конверсия — доля

δ — минимальный эффект (абсолютный) — доля

z — 1,96 для α = 5%; 0,84 для мощности 80% — –

```
Триал → оплата: p = 0,41; δ = 0,03 → n ≈ 16 · 0,242 / 0,0009 ≈ 4 300 на группу, 8 600 на тест
```

16.2 От выборки к неделям

8 600 стартов триала — это меньше двух недель трафика. Но решение о покупке приходит через 7 дней после старта триала, поэтому последний пользователь, вошедший в тест, должен ещё неделю дойти до конца триала. Итого: 2 полные недели набора и 1 неделя ожидания.

ГИПОТЕЗА	p	MDE	n НА ГРУППУ	ТРАФИК В НЕДЕЛЮ	НАБОР	ИТОГО С ОЖИДАНИЕМ
Г-07 тренировка в 1-й день, «похудеть»	31%	3 п.п.	3 800	9 000	1 нед. → 2 полные	2 нед.
Г-12 2-я тренировка за неделю	52%	2 п.п.	10 000	19 700	1,1 нед. → 2 полные	3 нед.
Г-03 триал → оплата	41%	3 п.п.	4 300	5 000	1,7 нед. → 2 полные	3 нед.
Г-24 отток через 30 дней после отмены	–	5 п.п.	1 500	950	3,2 нед. → 4 полные	8 нед.

ПРАВИЛО

Длительность — целое число недель, минимум одна полная неделя, даже если выборка набралась за три дня. Поведение в будни и выходные различается, и тест длиной в четыре дня измерит не того пользователя.

16.3 Подглядывание

Самая частая ошибка — каждый день смотреть на p-value и остановить тест, как только он стал «значимым». При ежедневной проверке двухнедельного теста вероятность ложной победы вырастает с 5% до 20–30%. Если нужно смотреть раньше, используют последовательные методы с поправкой (например, границы О'Брайена — Флеминга) или байесовский подход с заранее заданным правилом остановки.

МИРОВОЙ КЕЙС — Эван Миллер, «How Not To Run an A/B Test», 2010

Опасность подглядывания

Миллер показал на моделировании, что если проверять значимость после каждого нового пользователя и останавливать тест при p < 0,05, ложные победы случаются гораздо чаще заявленных 5%.

Его совет стал стандартом: зафиксируйте размер выборки заранее и не принимайте решение, пока он не набран.

ПЛОХО

Пока не станет значимым

«Посмотрим через пару дней».

На третий день p = 0,04 — тест остановлен, «победа».

ХОРОШО

Длительность заранее

«n = 4 300 на группу, 2 недели набора + 1 неделя ожидания».

Решение только после даты окончания.

16.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Остановка при первой значимости	Ложные победы	Фиксированная выборка или последовательный метод
Неполные недели	Перекос по дням	Целые недели
MDE «как получится»	Тест не видит реальный эффект	MDE из главы 11
Не учитывать отложенную конверсию	Неполные данные	Окно ожидания

16.5 Бенчмарки

БАЗОВАЯ КОНВЕРСИЯ	MDE 1 П.П.	MDE 2 П.П.	MDE 3 П.П.	MDE 5 П.П.
10%	14 400	3 600	1 600	580
30%	33 600	8 400	3 730	1 340
41%	38 700	9 680	4 300	1 550
50%	40 000	10 000	4 440	1 600

Таблица — размер группы при α = 5% и мощности 80%. Видно главное свойство: уменьшение MDE вдвое увеличивает выборку вчетверо. Поэтому смелые изменения с большим ожидаемым эффектом проверяются гораздо быстрее мелких.

ПРИМЕР

Онлайн-ритейл

Команда магазина останавливала тесты, как только видела p < 0,05. Ретроспективная проверка 30 «победивших» тестов повторными запусками подтвердила только 11. После перехода на фиксированную длительность доля подтверждённых побед выросла до 80%.

16.6 Вопросы для самопроверки

- Какие четыре входа нужны для расчёта выборки?
- Почему уменьшение MDE вдвое увеличивает выборку вчетверо?
- Почему длительность — целые недели?
- Что такое окно ожидания и когда оно нужно?
- Почему ежедневная проверка значимости даёт ложные победы?

ПРАКТИКА 16 после главы 16

Рассчитайте длительность трёх ближайших тестов.

ЧТО СДЕЛАТЬ

01	Возьмите базовую конверсию целевой метрики за последний месяц.	☐
02	Выберите MDE на основе ожидаемого эффекта из главы 11.	☐
03	Посчитайте размер группы по формуле (16.1).	☐
04	Переведите выборку в недели трафика, округлите до целых и добавьте окно ожидания.	☐

РЕЗУЛЬТАТ Если тест занимает больше 6–8 недель, увеличьте MDE (более смелое изменение) или выберите опережающую метрику.

17 План сбора данных и фиксации результатов

После неё вы пишете план эксперимента до запуска: гипотезу, метрики, события, расчёт выборки, правила решения — и защищаете результат от подгонки.

17.1 Шаблон плана
17.2 События и их проверка
17.3 Кейс «Формы»: тест, который пришлось повторить
17.4 Анти-паттерны
17.5 Кто согласует план
17.6 Вопросы для самопроверки

План эксперимента — короткий документ, который фиксирует все решения до запуска. Его главная задача — защитить команду от самой себя: после теста всегда хочется найти метрику, которая выросла, или сегмент, где сработало. Если правила записаны заранее, анализ становится проверкой, а не поиском подходящей истории.

17.1 Шаблон плана

```
Эксперимент Э-14 · Г-07 короткая первая тренировка
Гипотеза:     см. карточку Г-07
Варианты:     A — текущая 35-мин тренировка · B — 8-мин без инвентаря
Аудитория:    новые пользователи после выбора программы; главный сегмент «похудеть»
Деление:      по user_id, 50/50, точка — экран программы
Целевая:      доля начавших тренировку в 1-й день (31% → MDE 3 п.п.)
Вспомогат.:   доля завершивших тренировку · 2-я тренировка за 7 дней
Защитные:     старт триала · оценка тренировки · крэши
Выборка:      3 800 на группу в сегменте «похудеть» · 2 недели
Решение:      запуск, если целевая ≥ +2 п.п. при p < 0,05 и защитные не хуже -1 п.п.
События:      program_selected, workout_started, workout_completed, trial_started
Даты:         старт 3 марта · конец набора 16 марта · анализ 17 марта
```

17.2 События и их проверка

Каждое событие, на котором строится метрика, нужно проверить до запуска: срабатывает ли оно в обоих вариантах одинаково, есть ли у него user_id и вариант теста, не дублируется ли при повторном открытии экрана. Ошибка в событии обнаруживается обычно на анализе,

когда тест уже потрачен.

17.3 Кейс «Формы»: тест, который пришлось повторить

В первом тесте нового экрана триала событие trial_started в варианте B отправлялось при открытии экрана, а не при подтверждении. Конверсия B получилась 31% вместо ожидаемых 18–20%, и только сверка с данными стора показала ошибку. Тест повторили, потеряв три недели. После этого Артур ввёл правило: за два дня до старта тест запускается на сотрудниках, и события сверяются с внешним источником.

ПРАВИЛО

План пишется и согласуется до запуска и не меняется после. Если в процессе выяснилось, что план неверен, тест останавливается и запускается заново с новым планом — а не «поправляется на ходу».

МИРОВОЙ КЕЙС — Научные журналы, 2010-е; Center for Open Science

Предрегистрация

В науке после кризиса воспроизводимости распространилась предрегистрация: исследователь публично фиксирует гипотезы, методы и план анализа до сбора данных.

Продуктовые команды переняли ту же идею: план эксперимента в общей базе с датой создания — защита от подгонки результатов.

ПЛОХО

Решим после

«Запустим и посмотрим, что выросло».

После теста выбирается метрика с лучшим результатом.

ХОРОШО

Правила до запуска

Целевая, защитные, выборка и правило решения записаны.

Анализ — проверка заранее объявленного.

17.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Нет плана	Подгонка результатов	План по шаблону
События не проверены	Потерянные тесты	Запуск на сотрудниках, сверка
План меняется на ходу	Нет доверия к выводам	Перезапуск с новым планом

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Правило решения не записано	Спор после теста	Порог эффекта и защитных

17.5 Кто согласует план

РОЛЬ	ЧТО ПРОВЕРЯЕТ
Продакт	Гипотеза, правило решения, связь с рычагом
Аналитик	Метрики, события, выборка, сегменты
Разработчик	Деление, экспозиция, откат, влияние на другие тесты
Маркетинг	Пересечение с кампаниями и акциями

Согласование занимает в «Форме» один асинхронный круг комментариев в документе плана, обычно меньше дня. Зато за год ни один тест не был перезапущен из-за спора о метриках после окончания.

ПРИМЕР

Приложение знакомств

Тест нового экрана профиля показал +12% к лайкам, но событие лайка в варианте отправлялось дважды при двойном тапе. Сверка с серверными данными свела эффект к +1%. С тех пор каждый план содержит источник сверки для целевого события.

17.6 Вопросы для самопроверки

- [ ] Зачем писать план до запуска?
- [ ] Какие поля обязательны в плане?
- [ ] Как проверить события до старта теста?
- [ ] Что делать, если план оказался неверным?
- [ ] Кто должен согласовать план?

ПРАКТИКА 17 после главы 17

Напишите план ближайшего эксперимента по шаблону.

ЧТО СДЕЛАТЬ

01	Заполните все поля шаблона.	☐
02	Выпишите события для каждой метрики и проверьте их на тестовом пользователе.	☐
03	Сверьте ключевое событие с внешним источником: стор, платёжная система, база.	☐
04	Согласуйте правило решения с владельцем продукта до запуска.	☐

РЕЗУЛЬТАТ План готов, если по нему другой аналитик проведёт анализ без вопросов к автору.

18 Настройка трекинга и аналитики

После неё вы настраиваете раздачу вариантов, события и дашборд эксперимента, проверяете их до запуска и проводите A/A-тест, чтобы убедиться, что система не врёт.

18.1 Архитектура · 18.2 A/A-тест · 18.3 Кейс «Формы»: что нашёл A/A · 18.4 Анти-паттерны · 18.5 Бенчмарки · 18.6 Вопросы для самопроверки

Эксперимент держится на трёх технических опорах: система раздачи вариантов решает, кто что видит; события фиксируют поведение; хранилище и дашборд соединяют одно с другим. Ошибка в любой опоре делает результат бессмысленным, и чаще всего обнаруживается слишком поздно. Поэтому настройка и проверка — отдельный этап, а не «пара часов перед запуском».

18.1 Архитектура

Раздача вариантов	Сервис флагов или экспериментов детерминированно назначает вариант по хэшу user_id и id эксперимента. Один пользователь всегда в одном варианте.
Событие экспозиции	Отправляется в момент, когда пользователь впервые увидел вариант. Только такие пользователи попадают в анализ.
Продуктовые события	Действия пользователя с user_id, временем и версией приложения.
Расчёт	SQL или платформа экспериментов соединяет экспозиции и события и считает метрики по группам.

```
exposure  {user_id, experiment: 'E-14', variant: 'B', ts, platform, app_version}
workout_started  {user_id, workout_id, duration_plan: 8, ts}

-- доля начавших тренировку в 1-й день по вариантам
select e.variant, avg(case when w.user_id is not null then 1 else 0 end)
from exposures e left join first_workouts w
 on w.user_id = e.user_id and w.ts < e.ts + interval '24 hours'
where e.experiment = 'E-14' group by e.variant;
```

18.2 A/A-тест

A/A-тест — эксперимент, в котором обе группы видят одно и то же. Он проверяет систему: если раздача и расчёт работают правильно, группы должны быть одинаковыми, а «значимые» различия — встречаться примерно в 5% случаев. Если A/A регулярно показывает разницу, проблема в инструменте, и доверять A/B-тестам нельзя.

18.3 Кейс «Формы»: что нашёл A/A

ПЕРВЫЙ A/A-ТЕСТ

1. **Запуск**
   Пустой эксперимент на онбординге, 50/50, две недели.

2. **Дисбаланс**
   В группе A 50,9% пользователей, в B — 49,1%; при 60 000 участников это значимо ($p < 0{,}001$).

3. **Причина**
   В B на старых версиях Android флаг загружался дольше экрана, и часть пользователей не получала экспозицию.

✓ **Исправление**
Экспозиция отправляется при отрисовке варианта; повторный A/A — 50,02% / 49,98%.

ФОРМУЛА 18.1 · ПРОВЕРКА СООТНОШЕНИЯ ГРУПП (SRM)

$$\chi^2 = \Sigma \frac{(O_i - E_i)^2}{E_i} \quad (18.1)$$

где

O_i — наблюдаемое число пользователей в группе — чел.

E_i — ожидаемое при заданном делении — чел.

30 540 и 29 460 при ожидании 30 000/30 000 → χ^2 = 9,7 + 9,7 = 19,4; p < 0,001 — деление сломано

ПРАВИЛО

Проверяйте соотношение групп (SRM) в каждом эксперименте до анализа метрик. Если деление не совпадает с заданным, результаты не интерпретируются: сначала ищется причина.

МИРОВОЙ КЕЙС Фабиян и др., Microsoft и Booking.com, KDD 2019

SRM как главный индикатор проблем

Исследователи разобрали тысячи экспериментов и показали, что несоответствие соотношения групп встречается примерно в 6–10% тестов и почти всегда указывает на техническую ошибку: потерю событий, редиректы, ботов.

Их вывод: проверка SRM должна быть автоматической и блокировать отчёт об эксперименте.

ПЛОХО

Запустили и смотрим метрики

Сплит настроен, события «вроде есть».

Через две недели выясняется дисбаланс групп.

ХОРОШО

Проверка до и в первый день

A/A на новой точке, запуск на сотрудниках.

Автоматическая проверка SRM в первые сутки.

18.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Анализ по назначению, а не по экспозиции	Размывание и перекос	Событие экспозиции
Нет A/A	Ошибки инструмента незаметны	A/A при каждой новой точке
SRM проверяют вручную	Пропуски	Автоматическая проверка
Разные определения метрик в отчётах	Споры о цифрах	Единый слой метрик

18.5 Бенчмарки

ПОКАЗАТЕЛЬ	ОРИЕНТИР	«ФОРМА»
Доля тестов с SRM	до 2–3% после настройки	9% → 1%
Время настройки трекинга теста	до 1 дня	3 дня → 0,5 дня
A/A-тестов в год	1–2 на новую точку	5

Высокая доля SRM в начале — типичная ситуация для команды, которая впервые проверяет деление. Её снижение — лучший признак, что системе экспериментов можно доверять.

ПРИМЕР

Новостной портал

У портала SRM появлялся в каждом третьем тесте. Причиной оказались боты, которые чаще попадали в один вариант из-за разного времени загрузки. Фильтр ботов до назначения вариантов убрал дисбаланс и изменил выводы по двум «выигравшим» тестам.

18.6 Вопросы для самопроверки

- [ ] Почему анализ ведут по экспозиции, а не по назначению?
- [ ] Что проверяет A/A-тест?
- [ ] Как считается проверка SRM?

- Что делать, если SRM показал проблему?
- Зачем единое определение метрик?

ПРАКТИКА 18 после главы 18

Проверьте свою систему экспериментов A/A-тестом.

ЧТО СДЕЛАТЬ

01	Опишите путь данных: назначение → экспозиция → события → расчёт.	☐
02	Проверьте, что экспозиция отправляется при показе варианта, а не при назначении.	☐
03	Запустите A/A на неделю и проверьте SRM по формуле (18.1).	☐
04	Настройте автоматическую проверку SRM для всех будущих тестов.	☐

РЕЗУЛЬТАТ Если A/A провалился, ни один из прошлых A/B-тестов на этой точке нельзя считать надёжным без перепроверки.

19 Мониторинг ключевых метрик в процессе

После неё вы следите за экспериментом во время набора: здоровье данных, защитные метрики, технические ошибки, — и при этом не принимаете решение по целевой метрике раньше срока.

19.1 Что смотреть каждый день
19.2 Дашборд эксперимента
19.3 Кейс «Формы»: защитная метрика сработала
19.4 Эффект новизны
19.5 Анти-паттерны
19.6 Кейс «Формы»: эффект по дням
19.7 Вопросы для самопроверки

Во время эксперимента есть два разных вида наблюдения, и их важно не путать. Мониторинг здоровья — проверка, что тест идёт правильно и не вредит пользователям: события приходят, группы сбалансированы, приложение не падает, защитные метрики не обвалились. Его делают каждый день. Оценка результата по целевой метрике — делают один раз, в конце.

19.1 Что смотреть каждый день

ПРОВЕРКА	ПОРОГ ТРЕВОГИ	ДЕЙСТВИЕ
SRM	p < 0,001	Остановить и искать причину
Объём событий по группам	Расхождение > 5% при равном делении	Проверить трекинг
Крэши и ошибки	Рост > 0,1 п.п. в варианте	Остановить вариант
Защитные метрики	Ухудшение за пределы заданного порога с высокой уверенностью	Остановить, разобрать
Внешние события	Акции, сбои сторов, праздники	Записать в журнал теста

19.2 Дашборд эксперимента

У каждого эксперимента «Формы» есть одна страница: сверху — статус здоровья (SRM,

события, ошибки) зелёным или красным; ниже — защитные метрики с интервалами; целевая метрика скрыта до даты окончания набора. Скрытие придумал Артур после того, как в двух тестах подряд команда «увидела победу» на третий день.

19.3 Кейс «Формы»: защитная метрика сработала

ЭКСПЕРИМЕНТ Э-17: ЭКРАН ТРИАЛА БЕЗ КНОПКИ «ПРОПУСТИТЬ»

1 **День 2**
Старт триала в варианте B выше на 6 п.п. — целевая скрыта, но видна в защитных через воронку.

2 **День 3**
Защитная «удаление приложения в 1-й день» в B: 14% против 9% (интервал не пересекает ноль).

3 **День 3**
Отзывы в сторе: 11 новых жалоб «не дают пользоваться без подписки».

✓ **Решение**
Вариант B остановлен досрочно по защитной метрике; гипотеза переформулирована.

ПРАВИЛО

Досрочно останавливать можно из-за вреда, но не из-за успеха. Правила остановки по защитным метрикам записываются в план заранее, вместе с порогами.

19.4 Эффект новизны

В первые дни пользователи часто реагируют на новое сильнее, чем потом: изменение привлекает внимание, а через неделю становится привычным. Обратный эффект — непривычное сначала раздражает. Мониторинг эффекта по дням с момента входа в тест помогает заметить это: если разница между группами быстро сходится к нулю, долгосрочного эффекта может не быть.

МИРОВОЙ КЕЙС Booking.com, публикации команды экспериментов

Остановка по защитным метрикам

Booking.com, где одновременно идут тысячи экспериментов, автоматически отслеживает ключевые защитные метрики и может остановить тест, который заметно ухудшает бронирования или вызывает ошибки.

Решение «запускать или нет» при этом всё равно принимается по заранее объявленной целевой метрике после окончания набора.

ПЛОХО

Смотреть на целевую каждый день

«На третий день +6 п.п. — победа, раскатываем».

Через месяц эффект исчезает.

ХОРОШО

Здоровье каждый день, результат — в конце

Целевая скрыта до даты.

Защитные и техника — под ежедневным контролем.

19.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Остановка при «победе»	Ложные результаты	Только по вреду
Нет журнала событий	Непонятные аномалии	Журнал теста
Не смотреть защитные	Вред пользователям	Ежедневный мониторинг
Игнорировать новизну	Переоценка эффекта	Эффект по дням с входа

19.6 Кейс «Формы»: эффект по дням

ДНИ С ВХОДА В ТЕСТ	Δ «НАЧАЛИ ТРЕНИРОВКУ», П.П.	Δ «ОТКРЫЛИ ПРИЛОЖЕНИЕ», П.П.
1–3	+5,1	+6,2
4–7	+4,4	+2,1
8–14	+4,5	+0,4

Эффект Э-14 на целевую метрику стабилен, а вспомогательная «открыли приложение» быстро сходится к нулю — это эффект новизны нового превью. Решение принималось по

целевой, и стабильность эффекта по дням дала дополнительную уверенность.

ПРИМЕР

Онлайн-банк

Тест нового экрана перевода поднимал число переводов, но защитная метрика «обращения в поддержку о переводах» выросла на 40% на второй день. Тест остановили: новый экран путал получателей с похожими именами. Без мониторинга защитной метрики ошибка дошла бы до всех клиентов.

19.7 Вопросы для самопроверки

- Что мониторят каждый день, а что — в конце?
- Когда тест можно остановить досрочно?
- Зачем скрывать целевую метрику во время набора?
- Как заметить эффект новизны?
- Что записывать в журнал теста?

ПРАКТИКА 19 после главы 19

Соберите дашборд здоровья для ближайшего эксперимента.

ЧТО СДЕЛАТЬ

01	Добавьте проверки SRM, объёма событий и ошибок по группам.	☐
02	Выведите защитные метрики с интервалами.	☐
03	Скройте целевую метрику до даты окончания набора.	☐
04	Запишите пороги досрочной остановки в план.	☐

РЕЗУЛЬТАТ Дашборд должен отвечать на вопрос «всё ли в порядке с тестом» за десять секунд.

20 Реагирование на аномалии и фейлы

После неё вы различаете виды сбоев в эксперименте, решаете, остановить тест, исключить данные или перезапустить, и ведёте журнал, который сохраняет доверие к результатам.

20.1 Виды сбоев и реакции
20.2 Исключение данных: правило симметрии
20.3 Кейс «Формы»: акция посреди теста
20.4 Журнал эксперимента
20.5 Анти-паттерны
20.6 Бенчмарки
20.7 Вопросы для самопроверки

В реальном продукте эксперименты почти никогда не идут идеально. Падает сервер аналитики, выходит новая версия приложения, маркетинг запускает акцию, стор задерживает ревью. Важно не то, чтобы сбоев не было, а то, чтобы на каждый был понятный ответ, и решение о данных принималось по правилам, а не по тому, нравится ли команде результат.

20.1 Виды сбоев и реакции

СБОЙ	ПРИМЕР	РЕАКЦИЯ
Технический в варианте	Вариант B падает на iOS 16	Остановить вариант, исправить, перезапустить
Потеря данных	6 часов события не записывались	Исключить период для обеих групп, продлить тест
Дисбаланс групп (SRM)	51/49 при заданном 50/50	Остановить, найти причину, перезапустить
Внешнее событие	Рекламная акция с другим трафиком	Записать; проверить эффект до и после; при сильном влиянии — продлить
Ошибка в варианте	В B показывается не та тренировка	Остановить, перезапустить с нуля
Пересечение тестов	Два теста на одном экране	Проверить взаимодействие; при сильном — перезапуск

20.2 Исключение данных: правило симметрии

Данные можно исключать только симметрично и по причине, которая не зависит от варианта. Если 6 часов не работала аналитика, этот период убирается из обеих групп. Если «странные» пользователи нашлись только в одной группе, их нельзя выбросить: это может быть эффект варианта.

20.3 Кейс «Формы»: акция посреди теста

На девятый день Э-14 маркетинг запустил акцию «-50% на год» в рекламе, не предупредив продуктовую команду. Трафик новых пользователей вырос на 40%, а их мотивация оказалась другой: многие приходили за скидкой, а не за тренировками.

ЧТО СДЕЛАЛИ

1 **Журнал**
Событие записано с датой и источником трафика.

2 **Анализ по периодам**
Эффект до акции +4,6 п.п., во время — +3,9 п.п.; направление одно.

3 **Решение**
Тест продлён на неделю, чтобы набрать выборку без акционного трафика; итог по всему периоду и отдельно без акции.

✓ **Процесс**
Маркетинг теперь публикует акции в общем календаре экспериментов за неделю.

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Перезапускать тест, когда результат не понравился, под предлогом «был сбой». Решение о перезапуске принимается по факту сбоя и до взгляда на целевую метрику. Иначе перезапуск — это просто второй бросок монеты.

20.4 Журнал эксперимента

```
Э-14 · журнал
03.03  старт, SRM ок (50,1/49,9)
06.03  iOS 1.42 вышла в стор — версии в обеих группах одинаковые
11.03  акция маркетинга «-50% на год», +40% трафика — продлеваем на 7 дней
14.03  4 ч потери событий 02:00–06:00 — период исключён для обеих групп
23.03  конец набора; анализ 24.03
```

МИРОВОЙ КЕЙС Дмитриев, Кохави и др., Microsoft, KDD 2017

Двенадцать ловушек экспериментов

Команда Microsoft описала типичные ловушки, с которыми столкнулась на тысячах тестов: дисбаланс групп, ошибки в метриках, эффекты переноса между экспериментами, неверные единицы анализа.

Общий вывод статьи: необычно хорошие результаты чаще оказываются ошибкой, чем настоящей победой, и требуют дополнительной проверки (закон Твимена).

ПЛОХО

Чистка по вкусу

«Уберём пользователей из рекламы, они портят результат B».

Исключение только из одной группы.

ХОРОШО

Симметрия и журнал

Период сбоя исключён из обеих групп.

Каждое решение записано с датой и причиной.

20.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Перезапуск при плохом результате	Подгонка	Решение до взгляда на метрику
Несимметричное исключение	Искажение эффекта	Только для обеих групп
Нет журнала	Аномалии необъяснимы	Журнал с датами
Маркетинг не знает о тестах	Внешние помехи	Общий календарь

20.6 Бенчмарки

СБОЙ	ЧАСТОТА В ПРОГРАММЕ «ФОРМЫ» ЗА ГОД
Технический в варианте	4 из 46
Потеря данных	6 из 46
SRM	3 из 46
Внешнее событие (акции, праздники)	9 из 46
Перезапуск с нуля	5 из 46

Почти половина экспериментов столкнулась хотя бы с одним сбоем. Это норма для живого продукта, и именно поэтому правила реакции должны существовать заранее.

ПРИМЕР

Приложение для заметок

В середине теста вышло обновление iOS, и в варианте B перестали работать виджеты. Команда остановила только вариант B, исправила и перезапустила тест с новой датой — а не «исключила пользователей iOS из B», что исказило бы результат.

20.7 Вопросы для самопроверки

- Какие сбои требуют перезапуска с нуля?
- Что такое правило симметрии исключений?
- Как учесть внешнюю акцию в середине теста?
- Почему перезапуск после плохого результата — подгонка?
- Как предотвратить пересечения с маркетингом?

ПРАКТИКА 20 после главы 20

Подготовьте правила реакции на сбои до следующего теста.

ЧТО СДЕЛАТЬ

01	Составьте таблицу сбоев и реакций для своего продукта.	☐
02	Заведите шаблон журнала эксперимента.	☐
03	Договоритесь с маркетингом и релизами об общем календаре.	☐
04	Запишите правило симметрии исключений в регламент экспериментов.	☐

РЕЗУЛЬТАТ Правила, записанные до сбоя, не оспариваются после него.

21 Статистическая значимость и доверительные интервалы

После неё вы читаете p-value и доверительный интервал без типичных заблуждений, считаете интервал для разницы конверсий и понимаете, чем практическая значимость отличается от статистической.

21.1 p-value: что оно значит
21.2 Доверительный интервал
21.3 Практическая значимость
21.4 Множественные сравнения
21.5 Анти-паттерны
21.6 Кейс «Формы»: тест, который «не выиграл»
21.7 Вопросы для самопроверки

Результат эксперимента — не одно число, а оценка с неопределённостью. Группа B показала конверсию на 4,6 п.п. выше — но если повторить тест, разница может оказаться 2 или 7 п.п. Статистика отвечает на два вопроса: насколько вероятно увидеть такую разницу случайно, если эффекта нет, и в каком диапазоне скорее всего лежит настоящий эффект.

21.1 p-value: что оно значит

p-value — вероятность получить наблюдаемую разницу или большую при условии, что на самом деле эффекта нет. p = 0,01 означает: если бы варианты не отличались, такую разницу мы видели бы в 1% случаев. Это не вероятность того, что гипотеза верна, и не вероятность ошибки.

ЗАБЛУЖДЕНИЕ	КАК НА САМОМ ДЕЛЕ
p = 0,03 — гипотеза верна с вероятностью 97%	p ничего не говорит о вероятности гипотезы напрямую
p = 0,2 — эффекта нет	Эффект может быть; выборки не хватило, чтобы его увидеть
Меньше p — больше эффект	p зависит и от эффекта, и от размера выборки
p = 0,049 и p = 0,051 — разные выводы	Это почти одинаковая сила доказательств

21.2 Доверительный интервал

ФОРМУЛА 21.1 · 95% ИНТЕРВАЛ ДЛЯ РАЗНИЦЫ ДОЛЕЙ

$$\Delta \pm 1{,}96 \cdot \sqrt{\left(\frac{p_A(1-p_A)}{n_A} + \frac{p_B(1-p_B)}{n_B} \right)} \qquad (21.1)$$

где

p_A, p_B — конверсии групп — доля

n_A, n_B — размеры групп — чел.

Δ — p_B - p_A — доля

```
Э-14, «похудеть»: A 31,2% (n = 5 100), B 35,8% (n = 5 080) → Δ = 4,6 п.п.; σ = √(0,215/5 100 + 0,230/5 080) ≈ 0,94 п.п. → интервал 2,8…6,4 п.п.
```

Интервал не включает ноль — эффект статистически значим. Но интервал полезнее p-value: он показывает, что настоящий эффект скорее всего от 2,8 до 6,4 п.п. Даже нижняя граница выше порога решения в 2 п.п. из плана.

21.3 Практическая значимость

Статистически значимый эффект может быть практически бесполезным. На миллионе пользователей рост конверсии на 0,1 п.п. будет значимым, но не окупит поддержку новой функции. Поэтому в плане эксперимента порог решения задаётся в единицах метрики, а не только через p-value.

ИНТЕРВАЛ	ПОРОГ ЗАПУСКА +2 П.П.	ВЫВОД
+2,8… +6,4	целиком выше	Запускаем
+0,5… +3,9	частично выше	Эффект есть, но может быть мал — решаем с учётом стоимости
−1,2…+2,4	включает ноль	Не доказано; нужна большая выборка или более смелое изменение
−4,1…−0,8	целиком ниже нуля	Вариант вредит

21.4 Множественные сравнения

Если в тесте три варианта против контроля или пять сегментов, вероятность хотя бы одной ложной победы растёт. Простая защита — поправка Бонферрони: делить α на число сравнений. Для трёх вариантов плана Г-12 Артур использовал α = 0,05 / 3 ≈ 0,017 для каждого сравнения.

МИРОВОЙ КЕЙС — Американская статистическая ассоциация, 2016

Заявление о p-значениях

ASA впервые в истории выпустила официальное заявление о p-значениях: они не измеряют вероятность истинности гипотезы и не должны быть единственным основанием для выводов.

Ассоциация рекомендовала сообщать размер эффекта и интервалы и учитывать контекст, качество данных и число проведённых проверок.

ПЛОХО

Только p-value

«p = 0,03, значит, работает».

Неизвестно, насколько и стоит ли.

ХОРОШО

Эффект и интервал

«+4,6 п.п., интервал 2,8…6,4, порог +2 п.п. — выше всей границей».

Решение очевидно.

21.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Незначимо = эффекта нет	Отказ от работающих идей	Смотреть интервал
Нет поправки на сравнения	Ложные победы	Бонферрони или контроль FDR
Значимо = важно	Запуск бесполезного	Порог практической значимости
Отчёт без интервала	Ложная точность	Всегда интервал

21.6 Кейс «Формы»: тест, который «не выиграл»

Э-22 проверял напоминание о второй тренировке через 48 часов. Результат: +1,3 п.п. (−0,4… 3,0), p = 0,13. Команда хотела записать «не работает», но Артур показал, что интервал в основном положительный, а тест был рассчитан на MDE 3 п.п. Решение — «дорабатываем»:

более заметное напоминание и выборка под MDE 2 п.п. Повторный тест показал +2,2 п.п. (0,6...3,8).

ПРАВИЛО

«Незначимо» — это «не доказано при этой выборке», а не «эффекта нет». Перед отказом посмотрите, где лежит интервал и на какой MDE был рассчитан тест.

ПРИМЕР

Медиа-подписка

Издание тестировало 8 вариантов заголовка платного экрана и объявило победителя с p = 0,04. С поправкой Бонферрони порог был 0,006, и победитель не прошёл. Повторный тест двух лучших вариантов эффекта не показал.

21.7 Вопросы для самопроверки

- Что на самом деле означает p-value?
- Почему интервал полезнее p-value?
- Чем статистическая значимость отличается от практической?
- Что делать с «незначимым» результатом?
- Когда нужна поправка на множественные сравнения?

ПРАКТИКА 21 после главы 21

Пересчитайте результат последнего эксперимента с интервалом.

ЧТО СДЕЛАТЬ

01	Возьмите конверсии и размеры групп.	☐
02	Посчитайте разницу и 95% интервал по формуле (21.1).	☐
03	Сравните интервал с порогом практической значимости.	☐
04	Если вариантов или сегментов было несколько, примените поправку на множественные сравнения.	☐

РЕЗУЛЬТАТ Если вывод изменился по сравнению с исходным отчётом, обсудите это с командой — это ценный урок.

22 Интерпретация в контексте гипотезы и метрик

После неё вы объясняете результат через механизм гипотезы — что изменилось в поведении и почему, — проверяете согласованность вспомогательных метрик и формулируете выводы, применимые за пределами теста.

22.1 Кейс «Формы»: итоги Э-14
22.2 Вопросы интерпретации
22.3 Выводы для других гипотез
22.4 Анти-паттерны
22.5 Бенчмарки
22.6 Вопросы для самопроверки

Значимый результат по целевой метрике — только начало интерпретации. Важно понять, сработал ли механизм, который предполагала гипотеза. Если короткая тренировка подняла долю начавших, потому что люди перестали бояться сложности, это должно проявиться и во вспомогательных метриках: больше завершённых тренировок, меньше закрытий экрана, больше вторых тренировок. Если вспомогательные метрики говорят другое — механизм иной, и выводы надо скорректировать.

22.1 Кейс «Формы»: итоги Э-14

МЕТРИКА	A	B	Δ	ИНТЕРВАЛ
Начали тренировку в 1-й день («похудеть»)	31,2%	35,8%	+4,6 п.п.	2,8…6,4
Завершили первую тренировку	74%	89%	+15 п.п.	13…17
2-я тренировка за 7 дней	47%	51%	+4 п.п.	1,9…6,1
Старт триала	17,1%	17,6%	+0,5 п.п.	-0,9…1,9
Оценка тренировки ≥4	81%	86%	+5 п.п.	3…7
Другие сегменты: начали тренировку	38,4%	39,1%	+0,7 п.п.	-0,8…2,2

Картина согласованная. Пользователи чаще начинают и гораздо чаще завершают первую тренировку, лучше её оценивают и чаще возвращаются за второй. Это подтверждает механизм «страха сложности». Старт триала не изменился — короткая тренировка не

повлияла на решение подключить пробный период, но и не навредила. В других сегментах эффекта почти нет, как и предсказывала гипотеза.

22.2 Вопросы интерпретации

Механизм	Подтверждают ли вспомогательные метрики причину из гипотезы?
Масштаб	Соответствует ли эффект ожиданию? Сильно больший эффект — повод проверить ошибки.
Границы	Для кого работает и для кого нет? Только по объявленным сегментам.
Перенос	Что из этого применимо к другим гипотезам и точкам продукта?

ПРАВИЛО

Результат, который в несколько раз лучше ожидания, сначала считайте ошибкой. Проверьте SRM, события, исключения данных и только потом празднуйте. Это закон Твимена: любая цифра, которая выглядит интересной или необычной, скорее всего неверна.

22.3 Выводы для других гипотез

Главный вывод Э-14 оказался шире самой гипотезы: страх сложности — реальный барьер для сегмента «похудеть». Ксения подняла уверенность для трёх связанных гипотез: пояснение уровня рядом с превью тренировки, прогрессия нагрузки на первые две недели и креатив М-04 в рекламе. Отрицательный результат был бы не менее полезным: он снизил бы уверенность во всех трёх.

МИРОВОЙ КЕЙС Ронни Кохави, публичные разборы экспериментов Bing

Почему эффект оказался другим

Кохави приводит пример: небольшое изменение заголовков рекламы в Bing неожиданно увеличило выручку на 12%. Прежде чем поверить, команда многократно проверяла данные и повторяла эксперимент.

Эффект подтвердился, но именно его масштаб заставил искать ошибку — и такой подход, по словам Кохави, спасает от гораздо большего числа ложных побед.

ПЛОХО

Вывод по одной метрике

«+4,6 п.п. — гипотеза подтверждена».

Неясно, сработал ли механизм и на кого.

ХОРОШО

Вывод через механизм

«Чаще начинают и завершают, лучше оценивают, чаще возвращаются; эффект только у «похудеть»».

Ясно, что переносить на другие гипотезы.

22.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Только целевая метрика	Механизм не понят	Вспомогательные метрики
Объяснение задним числом	Истории под любой результат	Механизм из гипотезы
Слишком хороший результат без проверки	Ложные победы	Закон Твимена
Вывод не переносится	Знание теряется	Обновить уверенность связанных гипотез

22.5 Бенчмарки

РЕЗУЛЬТАТ	ДОЛЯ ТЕСТОВ «ФОРМЫ», ГДЕ МЕХАНИЗМ…
Подтвердился полностью	58% выигравших
Подтвердился частично	29% выигравших
Оказался другим	13% выигравших

Каждая восьмая победа «Формы» работала не так, как предполагала гипотеза. Например, напоминание до конца триала подняло оплату не потому, что люди вспоминали о тренировках, а потому, что меньше людей отменяли подписку из страха «внезапного списания».

ПРИМЕР

Образовательная платформа

Платформа увидела рост завершения курсов после добавления сертификатов. Вспомогательные метрики показали: выросло только завершение последнего урока, а промежуточные — нет. Люди перескакивали к концу ради сертификата. Механизм «мотивации учиться» не подтвердился, и сертификат стали выдавать за прохождение тестов.

22.6 Вопросы для самопроверки

- Зачем проверять механизм гипотезы?
- Что делать с результатом, который намного лучше ожидания?
- Как вспомогательные метрики подтверждают механизм?
- Почему выводы по необъявленным сегментам ненадёжны?
- Как результат теста влияет на связанные гипотезы?

ПРАКТИКА 22 после главы 22

Разберите последний эксперимент через механизм гипотезы.

ЧТО СДЕЛАТЬ

01	Выпишите, как должны были измениться вспомогательные метрики, если механизм верен.	☐
02	Сравните с фактом.	☐
03	Проверьте, соответствует ли масштаб эффекта ожиданию.	☐
04	Обновите уверенность в связанных гипотезах бэклога.	☐

РЕЗУЛЬТАТ Хорошая интерпретация умещается в три предложения: что изменилось, почему, что это значит для бэклога.

23 Выявление побочных эффектов и непредвиденных изменений

После неё вы ищете последствия эксперимента за пределами целевой метрики — каннибализацию, перенос между шагами воронки, влияние на долгосрочные метрики — и не принимаете перераспределение за рост.

23.1 Типы побочных эффектов
23.2 Кейс «Формы»: «победа», которая оказалась переносом
23.3 Долгосрочные эффекты
23.4 Анти-паттерны
23.5 Список проверок побочных эффектов
23.6 Вопросы для самопроверки

Изменение в продукте почти всегда влияет больше, чем на одну метрику. Рост конверсии на одном шаге может «украсть» пользователей у другого, рост краткосрочной метрики — ухудшить долгосрочную, а улучшение для одного сегмента — навредить другому. Побочные эффекты ищут целенаправленно: по защитным метрикам, по соседним шагам воронки и по отложенным результатам.

23.1 Типы побочных эффектов

ТИП	ПРИМЕР	КАК ЗАМЕТИТЬ
Перенос по воронке	Больше стартов триала, но ниже конверсия триала в оплату	Сквозная конверсия до денег
Каннибализация	Рост месячных подписок за счёт годовых	Выручка и структура тарифов
Краткосрочный против долгосрочного	Агрессивные напоминания: больше тренировок неделю, больше отписок от уведомлений	Метрики через 30–60 дней
Перераспределение времени	Больше тренировок одного типа, меньше другого	Общая активность, а не только целевая
Влияние на поддержку и репутацию	Больше обращений и негативных отзывов	Тикеты, рейтинг в сторе

23.2 Кейс «Формы»: «победа», которая оказалась переносом

Эксперимент Э-19 проверял более заметный экран триала: старт триала вырос с 18% до 22,5% — +25% относительно. Команда уже готовила раскатку, но Артур досчитал воронку до оплаты.

МЕТРИКА	A	B	Δ
Старт триала	18,0%	22,5%	+4,5 п.п.
Триал → оплата	41,0%	32,4%	-8,6 п.п.
Установка → оплата	7,38%	7,29%	-0,09 п.п. (незначимо)
Возвраты в первые 14 дней	1,6%	2,7%	+1,1 п.п.
Отзывы со словом «списали»	—	×1,8	рост

Новый экран привёл в триал людей, которые не собирались платить. Сквозная конверсия в оплату не изменилась, зато выросли возвраты и негативные отзывы. Вариант отклонили, а гипотезу переформулировали: целевая метрика экранов монетизации теперь — установка → оплата, а не старт триала.

ПРАВИЛО

Целевая метрика эксперимента должна быть как можно ближе к деньгам или к звезде, насколько позволяет трафик. Промежуточная метрика легко растёт за счёт перераспределения.

23.3 Долгосрочные эффекты

Некоторые эффекты видны только через месяцы: изменение онбординга может поднять активацию, но привлечь менее лояльных людей. Для таких случаев «Форма» оставляет небольшую контрольную группу — 5% пользователей без изменения — на 2–3 месяца после раскатки и сравнивает удержание. Подробнее о holdout-группах — в главе 29.

МИРОВОЙ КЕЙС Хоэнхаус и др., Google, «Focusing on the Long-term», KDD 2015

Кликбейт и долгосрочный вред

Исследователи Google показали, что увеличение числа рекламных объявлений на странице поднимает краткосрочную выручку, но приучает пользователей реже кликать по рекламе в будущем — эффект виден только через месяцы.

Они предложили моделировать долгосрочный эффект через длительные контрольные группы и учитывать его при решениях.

ПЛОХО

Рост промежуточной метрики

«Старт триала +25% — раскатываем».

Оплаты не выросли, возвраты выросли.

ХОРОШО

Сквозная проверка

Воронка до оплаты, возвраты, отзывы.

Решение по деньгам, а не по шагу.

23.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Целевая далеко от денег	Ложные победы	Сквозная метрика
Не смотреть соседние шаги	Перенос не виден	Вся воронка
Только краткосрочные метрики	Долгосрочный вред	Holdout
Игнорировать отзывы и поддержку	Репутационный ущерб	Тикеты и рейтинг как защитные

23.5 Список проверок побочных эффектов

- Воронка от точки теста до оплаты.
- Структура тарифов и выручка на пользователя.
- Возвраты, обращения в поддержку, отзывы.
- Активность в соседних разделах продукта.
- Удержание через 30 дней, если тест длится достаточно.
- Технические метрики: время загрузки, ошибки, батарея на мобильных.

В «Форме» этот список — часть шаблона отчёта, и пустой раздел «побочные эффекты» не позволяет перевести эксперимент в статус «решение».

ПРИМЕР

Подписка на музыку

Скидка на первый месяц увеличила число подписок на 30%, но через три месяца удержание этой когорты было на 18 п.п. ниже. В пересчёте на годовую выручку скидка оказалась убыточной. Тест повторили с более длинным окном анализа.

23.6 Вопросы для самопроверки

- Какие типы побочных эффектов встречаются чаще всего?
- Почему промежуточная метрика легко растёт за счёт переноса?
- Как обнаружить каннибализацию тарифов?
- Зачем смотреть на поддержку и отзывы?
- Как оценить долгосрочный эффект?

ПРАКТИКА 23 после главы 23

Проверьте последний выигравший эксперимент на побочные эффекты.

ЧТО СДЕЛАТЬ

01	Досчитайте воронку от точки теста до оплаты.	☐
02	Проверьте структуру тарифов и выручку.	☐
03	Сравните обращения в поддержку и отзывы по группам.	☐
04	Если есть данные, сравните удержание через 30 дней.	☐

РЕЗУЛЬТАТ Если хотя бы одна проверка показала ухудшение, пересмотрите решение о запуске.

24 Критерии «Запускаем / Дорабатываем / Отказываемся»

После неё вы принимаете решение по эксперименту по заранее заданной матрице, учитываете стоимость поддержки и риск и не оставляете результаты «в подвешенном состоянии».

24.1 Матрица решения · 24.2 Стоимость поддержки · 24.3 Кейс «Формы»: три решения за месяц · 24.4 Анти-паттерны · 24.5 Бенчмарки · 24.6 Вопросы для самопроверки

У эксперимента три честных исхода. Запускаем — изменение раскатывается на всех. Дорабатываем — механизм подтвердился частично, гипотезу нужно уточнить и проверить снова. Отказываемся — изменение не помогает или вредит, мы его убираем и фиксируем знание. Худший четвёртый исход — «оставим пока как есть»: вариант висит под флагом месяцами, усложняет код и мешает следующим тестам.

24.1 Матрица решения

ЦЕЛЕВАЯ МЕТРИКА	ЗАЩИТНЫЕ	МЕХАНИЗМ	РЕШЕНИЕ
Интервал выше порога	В норме	Подтверждён	Запускаем
Интервал выше нуля, но захватывает порог	В норме	Подтверждён	Запускаем, если поддержка дешёвая; иначе дорабатываем
Значимый рост	Хуже порога	—	Дорабатываем: ищем вариант без вреда
Интервал включает ноль	В норме	Частично	Дорабатываем: смелее изменение или другая аудитория
Интервал включает ноль	В норме	Не подтверждён	Отказываемся
Интервал ниже нуля	—	—	Отказываемся, фиксируем, что вредит

24.2 Стоимость поддержки

Каждое запущенное изменение — это код, который нужно поддерживать, и опыт, который нужно согласовывать с будущими изменениями. Маленький положительный эффект может не окупить сложность. Перед запуском Ксения задаёт вопрос: что изменится в работе команды, если мы это оставим? Для Г-07 ответ был простым — одна тренировка в контентной библиотеке и одна ветка онбординга.

ФОРМУЛА 24.1 · ОКУПАЕМОСТЬ ЗАПУСКА ЗА ГОД

$$V = 12 \cdot \Delta MRR_{\infty} - C_{\text{подд}} \tag{24.1}$$

где

ΔMRR_{∞} — прирост выручки в месяц после накопления эффекта ₽

$C_{\text{подд}}$ — стоимость поддержки за год: часы, контент, сложность ₽

```
Г-07: эффект 4,6 п.п. → ≈ +395 платящих в месяц → ΔMRR∞ ≈ 395 / 0,11 · 520 ≈ 1,87 млн ₽; C ≈ 0,3 млн ₽ → V ≈ 22 млн ₽
```

24.3 Кейс «Формы»: три решения за месяц

РЕШЕНИЯ МАРТА

1 **Э-14 Короткая первая тренировка**
+4,6 п.п. (2,8…6,4), защитные в норме, механизм подтверждён → запускаем для «похудеть».

2 **Э-19 Заметный экран триала**
Старт триала +4,5 п.п., но сквозная оплата без изменений и возвраты выше → отказываемся.

3 **Э-16 План на 7 дней**
2-я тренировка +1,2 п.п. (-0,4…2,8); у варианта с датами — +2,6 п.п. → дорабатываем: тест только варианта с датами и напоминанием.

✓ **Итог**
Ни один тест не остался «подвешенным»; флаги проигравших удалены за неделю.

ПРАВИЛО

Решение принимается в течение недели после окончания теста. Флаг проигравшего варианта удаляется в следующем спринте. Код, который никто не собирается запускать, — технический долг.

МИРОВОЙ КЕЙС Booking.com, интервью руководителей экспериментов

Культура «большинство идей не работает»

Руководители Booking.com рассказывали, что в компании идут тысячи экспериментов в год, и около 90% из них не дают положительного результата. Это считается нормой, а не провалом.

Ценность программы — в быстром отказе от неработающих идей и в знании, которое остаётся после каждого теста.

ПЛОХО

Решение «потом»

«Результат неоднозначный, оставим флаг, посмотрим ещё».

Через полгода — 14 висящих флагов.

ХОРОШО

Решение по матрице

Неоднозначно → «дорабатываем» с новой гипотезой и датой.

Флаги проигравших удалены.

24.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Висящие флаги	Сложность кода, помехи тестам	Решение за неделю
Запуск «раз уж сделали»	Бесполезная сложность	Окупаемость (24.1)
Отказ без записи	Повтор той же идеи	Запись в базу знаний
Решение по настроению руководителя	Недоверие к экспериментам	Матрица, согласованная заранее

24.5 Бенчмарки

ИСХОД	ОРИЕНТИР ДЛЯ ЗРЕЛЫХ ПРОДУКТОВ	«ФОРМА» ЗА ГОД
Запускаем	10–33%	30%
Дорабатываем	10–20%	20%
Отказываемся	50–75%	50%

Доля побед «Формы» выше, чем у зрелых продуктов, потому что продукт молодой и в нём много неоптимизированных мест. По мере роста она будет снижаться — это ожидаемо и не означает, что команда стала работать хуже.

ПРИМЕР

Saas для команд

Сервис запустил выигравшую функцию с эффектом +0,4% к конверсии. Её поддержка требовала отдельного сервиса и дежурств. Через полгода функцию удалили: окупаемость не покрывала затраты. Теперь каждое решение «запускаем» включает расчёт стоимости поддержки.

24.6 Вопросы для самопроверки

- Какие три честных исхода у эксперимента?
- Почему «оставим пока под флагом» — плохое решение?
- Как учитывать стоимость поддержки?
- Что делать, если целевая выросла, а защитная ухудшилась?
- За какой срок нужно принять решение?

ПРАКТИКА 24 после главы 24

Примите решения по всем завершённым экспериментам.

ЧТО СДЕЛАТЬ

01	Соберите эксперименты, по которым нет решения.	☐
02	Пройдите по матрице для каждого.	☐
03	Для «запускаем» посчитайте окупаемость по формуле (24.1).	☐
04	Для «дорабатываем» сформулируйте новую гипотезу с датой.	☐
05	Заведите задачи на удаление флагов проигравших вариантов.	☐

РЕЗУЛЬТАТ Если висящих экспериментов больше трёх, запретите новые запуски, пока не примете решения по старым.

25 Документирование результатов

После неё вы записываете каждый эксперимент в короткий отчёт по шаблону, храните отчёты в базе знаний с поиском и превращаете накопленные результаты в институциональную память продукта.

25.1 Шаблон отчёта · 25.2 Что делает базу полезной · 25.3 Кейс «Формы»: база через год · 25.4 Анти-паттерны · 25.5 Теги базы знаний · 25.6 Вопросы для самопроверки

Эксперимент без записи — потраченный трафик. Через год никто не вспомнит, почему короткая тренировка стала первой, какие варианты плана проверяли и что проиграло. Новый продакт предложит ту же идею, команда потратит ещё месяц. База знаний экспериментов — главный актив программы гипотез, и он растёт, только если каждый тест записан.

25.1 Шаблон отчёта

```
Э-14 · Короткая первая тренировка · ЗАПУСКАЕМ
Гипотеза:   Г-07 — страх сложности у «похудеть» мешает начать
Даты:       3–23 марта · 20 180 пользователей · сегмент «похудеть» 10 180
Результат:  тренировка в 1-й день +4,6 п.п. (2,8…6,4), p < 0,001
Механизм:   завершили +15 п.п., 2-я тренировка +4 п.п., оценка +5 п.п.
Защитные:   старт триала +0,5 (-0,9…1,9), крэши без изменений
Сегменты:   эффект только у «похудеть», остальные ≈ 0 (объявлено заранее)
Сбои:       акция 11.03 — эффект до/во время одного знака; 4 ч потери событий
Решение:    раскатка на «похудеть» с 27 марта; holdout 5% на 8 недель
Знание:     страх сложности подтверждён; ↑ уверенность Г-08, Г-09, М-04
Ссылки:     план · дашборд · запрос · макеты
```

25.2 Что делает базу полезной

Единый шаблон	Любой отчёт читается за две минуты, поля одинаковые.

Теги	Точка продукта, рычаг, тип изменения, сегмент, исход: поиск «все тесты экрана оплаты, которые проиграли».
Проигрыши наравне с победами	Половина ценности — в том, что не работает.
Раздел «знание»	Вывод, который переносится на другие гипотезы, сформулирован явно.
Ссылки на данные	План, запрос и дашборд — чтобы результат можно было перепроверить.

25.3 Кейс «Формы»: база через год

За год в базе «Формы» накопилось 46 отчётов. Когда в компанию пришёл новый дизайнер и предложил «убрать кнопку пропуска с экрана триала», поиск по тегу «экран триала» за минуту нашёл Э-17 с остановкой по защитной метрике и Э-19 с переносом по воронке. Идею не пришлось проверять заново — дизайнер предложил вариант, который учитывал оба урока.

ИСХОД	ЧИСЛО	ДОЛЯ
Запускаем	14	30%
Дорабатываем → повторный тест	9	20%
Отказываемся (нейтрально)	12	26%
Отказываемся (вредит)	11	24%
Итого	**46**	**100%**

ПРАВИЛО

Отчёт пишется в день решения и занимает не больше страницы. Если для отчёта нужен день работы, шаблон слишком сложный.

МИРОВОЙ КЕЙС Microsoft ExP, Netflix, Airbnb — публикации платформ экспериментов

Репозиторий экспериментов

Крупные компании хранят все эксперименты в общих репозиториях с поиском по продукту, метрике и результату. В Microsoft и Airbnb, по их публикациям, это используется для мета-анализа: какие типы изменений обычно выигрывают и какой эффект типичен.

Мета-анализ возможен только тогда, когда отчёты единообразны и включают проигрыши.

ПЛОХО

Результат в чате

«Короткая тренировка выиграла, раскатываем!».

Через год сообщение не найти, деталей нет.

ХОРОШО

Отчёт в базе

Шаблон, теги, механизм, сбои, знание, ссылки.

Ищется за минуту, перепроверяется по запросу.

25.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Записывать только победы	Повтор проигравших идей	Все исходы
Отчёт-презентация на 30 слайдов	Никто не пишет и не читает	Страница по шаблону
Нет тегов	Поиск невозможен	Точка, рычаг, исход
Нет раздела «знание»	Выводы не переносятся	Явный вывод

25.5 Теги базы знаний

ТЕГ	ЗНАЧЕНИЯ
Точка	онбординг, первая тренировка, экран триала, экран оплаты, напоминания, экран отмены
Рычаг	активация, регулярность, триал → оплата, отток, ARPPU
Тип изменения	контент, интерфейс, тексты, цена, уведомления, техника
Сегмент	похудеть, сила, гибкость, без цели, все

ТЕГ	ЗНАЧЕНИЯ
Исход	запуск, доработка, отказ-нейтрально, отказ-вред

Пяти тегов хватает, чтобы ответить на большинство вопросов: что пробовали на экране оплаты, какие изменения цены выигрывали, что работает для сегмента «сила».

ПРИМЕР

Продуктовая компания

После смены команды продукт три раза за два года проверял одну и ту же гипотезу о бесплатном пробном периоде без карты — каждый раз с тем же результатом. После создания базы знаний с поиском такие повторы прекратились.

25.6 Вопросы для самопроверки

- Что должно быть в отчёте об эксперименте?
- Почему проигрыши важно документировать наравне с победами?
- Какие теги нужны базе знаний?
- Сколько времени должен занимать отчёт?
- Как база помогает при новых гипотезах?

ПРАКТИКА 25 после главы 25

Заведите базу знаний экспериментов.

ЧТО СДЕЛАТЬ

01	Создайте шаблон отчёта на одну страницу.	☐
02	Договоритесь о тегах: точка, рычаг, тип изменения, исход.	☐
03	Перенесите в базу последние 5–10 экспериментов, включая проигравшие.	☐
04	Добавьте поиск базы в процесс формулировки новых гипотез.	☐

РЕЗУЛЬТАТ Перед каждой новой гипотезой — поиск по базе: возможно, похожее уже проверяли.

26 Обновление бэклога гипотез

После неё вы пересчитываете уверенность и приоритеты бэклога после каждого теста, порождаете следующие гипотезы из результатов и поддерживаете бэклог в актуальном состоянии.

26.1 Что обновляется
26.2 Следующий шаг из результата
26.3 Кейс «Формы»: цепочка гипотез
26.4 Анти-паттерны
26.5 Бенчмарки
26.6 Вопросы для самопроверки

Каждый эксперимент меняет то, что мы знаем о продукте, а значит — и бэклог. Победа поднимает уверенность в связанных гипотезах и подсказывает следующие шаги. Проигрыш снижает уверенность в целом направлении. Бэклог, который не обновляется после тестов, через квартал описывает продукт, которого уже нет.

26.1 Что обновляется

ЧТО	КАК	ПРИМЕР ПОСЛЕ Э-14
Уверенность связанных гипотез	Вверх после победы, вниз после проигрыша	Г-08 пояснение уровня: 50% → 80%
Ожидаемый эффект	По фактическому эффекту похожего теста	Гипотезы онбординга: медиана 1,8 → 2,5 п.п.
Новые гипотезы	Из механизма и неожиданных наблюдений	Г-31 короткие тренировки всю первую неделю
Ёмкость точки	Точка освобождается или занята holdout	Онбординг «похудеть» свободен с 27 марта
Статус	Решение по исследованной гипотезе	Г-07 → «запущена»

26.2 Следующий шаг из результата

Хороший результат почти всегда порождает вопрос «а что дальше». Если короткая первая

тренировка помогает начать, поможет ли короткая вторая? А прогрессия нагрузки? Ксения записывает такие вопросы сразу при написании отчёта — в момент, когда контекст свежий. Через год половина гипотез бэклога «Формы» выросла из результатов прошлых тестов.

26.3 Кейс «Формы»: цепочка гипотез

ОТ Э-14 К СЛЕДУЮЩИМ ТЕСТАМ

1 **Э-14 (запуск)**
Короткая первая тренировка: +4,6 п.п. к началу в 1-й день.

2 **Г-31**
Короткие тренировки всю первую неделю → 2-я тренировка +3 п.п. (выиграла: +2,7).

3 **Г-35**
Плавная прогрессия до 20 минут к третьей неделе → регулярность М1 +2 п.п. (выиграла: +1,9).

4 **М-04**
Креатив «8 минут без инвентаря» → активация рекламного трафика +3 п.п. (выиграла).

✓ **Итог**
Одно открытие — четыре выигрыша за пять месяцев.

ПРАВИЛО

После каждого теста задайте три вопроса: что это говорит о связанных гипотезах, какой следующий шаг подсказывает механизм и что удивило. Ответы — в бэклог в тот же день.

МИРОВОЙ КЕЙС Томас Байес, 1763; современная практика экспериментов

Байесовское обновление

Идея Байеса проста: убеждение до наблюдения (априорное) обновляется данными и становится апостериорным. Сильные данные меняют убеждение сильно, слабые — немного.

Шкала уверенности в бэклоге — упрощённый вариант того же: каждая гипотеза несёт текущую степень убеждения, и каждый тест её обновляет.

ПЛОХО

Бэклог не меняется

После победы Г-07 оценки остальных гипотез прежние.

Связанные гипотезы ждут в конце очереди.

ХОРОШО

Бэклог учится

Уверенность Г-08, Г-31, М-04 поднята.

Новые гипотезы из механизма добавлены в тот же день.

26.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Пересмотр раз в квартал	Устаревшие приоритеты	После каждого теста
Только новые идеи со стороны	Потеря цепочек	Гипотезы из результатов
Проигрыш не влияет на бэклог	Повтор провального направления	Снижение уверенности связанных
Бэклог растёт без чистки	Шум	Удалять гипотезы старше двух кварталов без движения

26.5 Бенчмарки

ПОКАЗАТЕЛЬ БЭКЛОГА	«ФОРМА» В НАЧАЛЕ	ЧЕРЕЗ ГОД
Гипотез в работе	58 идей без оценок	34 оценённые гипотезы
Доля гипотез из результатов прошлых тестов	0%	48%
Медиана возраста гипотезы в бэклоге	—	5 недель
Гипотез старше двух кварталов	—	0 (чистка)

ПРИМЕР

Проигрыш как источник

После отказа от Э-19 (заметный экран триала) Ксения записала гипотезу Г-29: если честно показывать дату списания на экране триала, конверсия в оплату вырастет за счёт меньшего числа отмен. Г-29 выиграла: +1,8 п.п. к оплате и −0,7 п.п. возвратов.

ПРИМЕР

Сервис записи к врачу

Тест напоминаний за сутки до приёма снизил неявки на 3 п.п. Команда сразу записала три следующих гипотезы: напоминание за два часа, кнопку переноса в напоминании и подтверждение приёма. Две из трёх выиграли, и неявки упали ещё на 4 п.п.

26.6 Вопросы для самопроверки

- Что обновляется в бэклоге после теста?
- Как победа влияет на связанные гипотезы?
- Как проигрыш становится источником новой гипотезы?
- Как быстро записывать новые гипотезы из результатов?
- Когда удалять гипотезы из бэклога?

ПРАКТИКА 26 после главы 26

Обновите бэклог по результатам последних экспериментов.

ЧТО СДЕЛАТЬ

01	Для каждого завершённого теста найдите связанные гипотезы и пересчитайте уверенность.	☐
02	Обновите ожидаемый эффект по фактическим результатам.	☐
03	Запишите 2–3 новые гипотезы, которые подсказывает механизм.	☐
04	Удалите гипотезы, которые потеряли смысл.	☐

РЕЗУЛЬТАТ Хороший признак зрелости — половина новых гипотез приходит из результатов прошлых тестов.

27 Постепенное расширение на другие сегменты

После неё вы раскатываете выигравшее изменение поэтапно — по долям трафика, сегментам, платформам и странам — проверяете, переносится ли эффект, и знаете, когда остановить раскатку.

27.1 Ступени раскатки
27.2 Перенос на сегменты — новая гипотеза
27.3 Кейс «Формы»: англоязычная версия
27.4 Когда остановить раскатку
27.5 Анти-паттерны
27.6 Кейс «Формы»: перенос эффектов
27.7 Вопросы для самопроверки

Победа в эксперименте доказывает эффект для аудитории теста. Перенести его на всех — отдельный шаг с собственными рисками: другие сегменты могут реагировать иначе, нагрузка на инфраструктуру вырастет, а на другой платформе изменение может работать хуже. Поэтому раскатка идёт ступенями, и на каждой проверяется, что эффект сохраняется, а вреда нет.

27.1 Ступени раскатки

СТУПЕНЬ	ДОЛЯ	ЧТО ПРОВЕРЯЕМ	ДЛИТЕЛЬНОСТЬ
Аудитория теста	50% сегмента	Эффект подтверждён тестом	—
Весь сегмент теста	95% (5% holdout)	Техника, нагрузка, защитные	1 неделя
Соседний сегмент	A/B 50/50	Переносится ли эффект	по расчёту выборки
Другая платформа или страна	A/B 50/50	Переносится ли эффект	по расчёту выборки
Все	95–100%	Долгосрочные метрики через holdout	8–12 недель

27.2 Перенос на сегменты — новая гипотеза

Если эффект в соседних сегментах не был доказан в исходном тесте, перенос — это новая

гипотеза, и её проверяют новым экспериментом. В Э-14 у сегментов «сила» и «гибкость» эффект был около нуля — короткая тренировка им не нужна, они и так начинают чаще. Раскатывать изменение на них не стали.

27.3 Кейс «Формы»: англоязычная версия

Через два месяца «Форма» запускала англоязычную версию для нескольких стран. Короткую первую тренировку включили сразу, но в режиме A/B: аудитория другая, и уверенность в переносе — 50%. Результат: +2,1 п.п. (0,3...3,9) против +4,6 у русскоязычного сегмента. Эффект есть, но вдвое меньше. Интервью показали причину: в этих странах больше пользователей приходят с опытом тренировок, и страх сложности слабее.

ПЛАН РАСКАТКИ Г-07

1 **27 марта**
95% сегмента «похудеть», RU, обе платформы; 5% holdout.

2 **3 апреля**
Проверка техники и защитных: в норме.

3 **Май**
A/B на англоязычной версии: +2,1 п.п. → раскатка.

✓ **Не раскатываем**
Сегменты «сила» и «гибкость»: эффекта нет, лишняя ветка онбординга не нужна.

ПРАВИЛО

Раскатывайте только туда, где эффект доказан или где проверка идёт прямо сейчас. «Если работает здесь, сработает и там» — гипотеза, а не вывод.

27.4 Когда остановить раскатку

- Защитные метрики ухудшились на новой ступени.
- Эффект на новой аудитории не отличается от нуля при достаточной выборке.
- Выросли ошибки, время загрузки или нагрузка на поддержку.

- Изменение конфликтует с другим запущенным изменением.

МИРОВОЙ КЕЙС — Facebook, Google — практика staged rollout

Постепенная раскатка

Крупные компании выкатывают изменения ступенями: сотрудники, 1%, 5%, 25%, 100% — с автоматическими проверками на каждом шаге. Это позволяет поймать проблему, пока она затронула малую часть пользователей.

Мобильные сторы поддерживают такую же поэтапную публикацию версии приложения, и её стоит использовать для изменений, которые нельзя выключить флагом.

ПЛОХО

Сразу на всех

«Выиграло в RU — включаем везде».

Эффект на других рынках неизвестен.

ХОРОШО

Ступенями с проверкой

Сегмент теста → соседние через A/B → все.

На каждом шаге — эффект и защитные.

27.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Перенос без проверки	Нулевой или отрицательный эффект	A/B на новой аудитории
Раскатка без holdout	Нельзя оценить долгосрочно	5% контроля
Нет критериев остановки	Вред распространяется	Список стоп-сигналов
Раскатка на сегменты без эффекта	Лишняя сложность	Только где помогает

27.6 Кейс «Формы»: перенос эффектов

ИЗМЕНЕНИЕ	ИСХОДНЫЙ СЕГМЕНТ	НОВАЯ АУДИТОРИЯ	ЭФФЕКТ НА НОВОЙ
Короткая первая тренировка	RU, «похудеть»: +4,6	EN, «похудеть»	+2,1
Напоминание до конца триала	iOS: +2,4	Android	+2,6
Годовой тариф первым	Казахстан: +5	Россия	+3,8

ИЗМЕНЕНИЕ	ИСХОДНЫЙ СЕГМЕНТ	НОВАЯ АУДИТОРИЯ	ЭФФЕКТ НА НОВОЙ
План на 7 дней с датами	«сила»: +2,6	«похудеть»	+0,3 (не переносится)

Из четырёх переносов три сработали, но с другим масштабом, а один не сработал совсем. Это и есть причина, по которой перенос проверяется отдельным тестом.

ПРИМЕР

Глобальное приложение

Изменение онбординга выиграло в США (+6%) и было раскатано на все страны. В Японии конверсия упала на 4%: новый текст воспринимался как навязчивый. Поэтапная раскатка с A/B на крупных рынках поймала бы это за две недели.

27.7 Вопросы для самопроверки

- Почему перенос эффекта на новый сегмент — новая гипотеза?
- Какие ступени раскатки нужны?
- Когда остановить раскатку?
- Зачем оставлять holdout при раскатке?
- Почему не раскатывать туда, где эффекта нет?

ПРАКТИКА 27 после главы 27

Составьте план раскатки для последнего выигравшего изменения.

ЧТО СДЕЛАТЬ

01	Определите, для каких сегментов эффект доказан.	☐
02	Распишите ступени с долями и сроками.	☐
03	Для недоказанных сегментов запланируйте отдельные A/B-тесты.	☐
04	Запишите стоп-сигналы и оставьте holdout.	☐

РЕЗУЛЬТАТ Хороший план раскатки помещается в пять строк и называет, где изменение не включаем.

28 Интеграция в основную продуктовую версию

После неё вы превращаете экспериментальный код в постоянную часть продукта: доделываете то, что упростили для теста, удаляете флаги, обновляете документацию и метрики.

28.1 Чек-лист интеграции
28.2 Флаговый долг
28.3 Кейс «Формы»: правило двух спринтов
28.4 Анти-паттерны
28.5 Бенчмарки
28.6 Вопросы для самопроверки

Экспериментальная версия делалась минимально: без крайних случаев, локализации, админки и аккуратной архитектуры. Это правильно для теста, но опасно для продукта, если так и оставить. После решения «запускаем» нужен отдельный этап — довести изменение до продуктового качества и убрать экспериментальные леса.

28.1 Чек-лист интеграции

ЭТАП	ЧТО ДЕЛАЕМ	Г-07
Доделать упрощения	Крайние случаи, локализация, доступность	Субтитры, версия для слабого интернета
Удалить флаг	Старая ветка кода уходит, условие убирается	Удалена ветка 35-минутной первой тренировки для «похудеть»
Контент и инструменты	Редакторам — возможность менять без разработки	Первая тренировка выбирается в админке
Аналитика	События эксперимента становятся постоянными, метрика — в дашборде продукта	«Начали в 1-й день» по сегментам — в основном дашборде
Документация	Описание поведения для поддержки и новых сотрудников	Статья в базе поддержки
Тесты	Автотесты на новый сценарий	2 UI-теста онбординга

28.2 Флаговый долг

Каждый флаг эксперимента — это ветвление в коде. Когда флагов десятки, комбинаций становятся тысячи, и никто не может сказать, что видит конкретный пользователь. В «Форме» к середине года накопилось 23 флага, из них 15 — от завершённых тестов. Новый тест онбординга случайно взаимодействовал со старым флагом и дал необъяснимый результат.

ФОРМУЛА 28.1 · ЧИСЛО СОСТОЯНИЙ ПРОДУКТА

$$N = 2^{f} \tag{28.1}$$

где

f — число двоичных флагов, влияющих на один сценарий — шт.

```
6 флагов на онбординге → 64 варианта сценария, которые теоретически нужно тестировать;
после чистки до 2 — 4 варианта
```

28.3 Кейс «Формы»: правило двух спринтов

После инцидента с флагами команда ввела правило: флаг выигравшего эксперимента удаляется в течение двух спринтов после решения, проигравшего — в течение одного. Задача на удаление создаётся автоматически при записи решения в базу знаний. Через квартал флагов стало 8, и все относились к идущим тестам или holdout-группам.

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Оставить флаг «на всякий случай, вдруг придётся откатить». Откатывать через полгода никто не будет, а флаг мешает каждому следующему изменению. Возможность отката нужна на время holdout, после — удаление.

МИРОВОЙ КЕЙС — Пит Ходжсон, «Feature Toggles», martinfowler.com, 2017

Флаги как долг

Ходжсон разделил флаги на типы: для релизов, экспериментов, операционные и для прав доступа, — и показал, что у экспериментальных флагов самый короткий срок жизни.

Он советует с самого создания флага планировать его удаление и считать количество активных флагов метрикой здоровья кодовой базы.

ПЛОХО

Эксперимент навсегда

Вариант B включён на 100% через флаг.

Упрощения теста остались в продукте.

ХОРОШО

Интеграция

Упрощения доделаны, флаг удалён.

Метрика в основном дашборде, поведение задокументировано.

28.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Флаги не удаляются	Взаимодействие, сложность	Правило двух спринтов
Экспериментальный код в продукте	Ошибки в крайних случаях	Этап доделки
Метрика эксперимента исчезает	Нельзя следить за эффектом	Перенос в дашборд продукта
Поддержка не знает об изменении	Неверные ответы пользователям	Документация

28.5 Бенчмарки

ПОКАЗАТЕЛЬ	ОРИЕНТИР	«ФОРМА»
Активных флагов экспериментов на команду	до 10	23 → 8
Срок от решения до удаления флага	до 2 спринтов	3 месяца → 3 недели
Доля запусков с доделкой упрощений	100%	100% после правила

Флаги — самый наглядный индикатор того, завершает ли команда эксперименты по-настоящему или только объявляет решения.

ПРИМЕР

Финтех-приложение

В приложении накопилось 60 флагов. Инцидент с неверным отображением баланса оказался результатом комбинации двух старых флагов, о которых никто не помнил. После чистки до 12 флагов скорость разработки новых функций выросла, а число регрессионных багов упало.

28.6 Вопросы для самопроверки

- Что нужно доделать после решения «запускаем»?
- Почему флаги экспериментов — долг?
- Сколько состояний создают 6 флагов?
- Когда удалять флаг выигравшего варианта?
- Почему важно обновить документацию поддержки?

ПРАКТИКА 28 после главы 28

Проведите ревизию флагов экспериментов.

ЧТО СДЕЛАТЬ

01	Выпишите все активные флаги и связанные эксперименты.	☐
02	Отметьте флаги завершённых тестов.	☐
03	Для выигравших — составьте задачи доделки и удаления флага.	☐
04	Для проигравших — удалите флаг в ближайшем спринте.	☐
05	Введите правило срока жизни флага.	☐

РЕЗУЛЬТАТ Число активных флагов — простая метрика здоровья программы экспериментов.

29 Пост-анализ долгосрочного влияния

После неё вы проверяете, сохраняется ли эффект через месяцы, с помощью holdout-групп и когортного анализа и честно оцениваете суммарный вклад программы экспериментов в цель.

29.1 Holdout-группа
29.2 Кейс «Формы»: эффект через 8 недель
29.3 Суммарный вклад за год
29.4 Итог года «Формы»
29.5 Анти-паттерны
29.6 Как устроен глобальный holdout «Формы»
29.7 Вопросы для самопроверки

Эксперимент длится две-три недели, а цель «Формы» — выручка через год. Между ними остаётся вопрос: держится ли эффект? Пользователи привыкают, новизна проходит, а изменения взаимодействуют друг с другом. Сумма эффектов отдельных тестов почти всегда больше реального прироста, и чтобы знать правду, нужна долгосрочная проверка.

29.1 Holdout-группа

Holdout — небольшая доля пользователей, которая не получает запущенное изменение в течение нескольких месяцев. Сравнение с ней показывает долгосрочный эффект. Глобальный holdout идёт дальше: 3–5% пользователей не получают ни одного изменения за квартал, и сравнение с ними показывает суммарный вклад всех запусков.

29.2 Кейс «Формы»: эффект через 8 недель

МЕТРИКА	HOLDOUT 5%	РАСКАТКА 95%	Δ ЧЕРЕЗ 8 НЕД.	Δ В ТЕСТЕ
Начали в 1-й день («похудеть»)	31,0%	35,1%	+4,1 п.п.	+4,6 п.п.
Регулярны в M1	38%	41%	+3 п.п.	—
Платящие на 1 000 установок	69	73	+4	—
Отток платящих M2	13,2%	12,4%	-0,8 п.п.	—

Эффект на активацию немного снизился, но держится. Важнее, что он дошёл до денег: на тысячу установок стало на четыре платящих больше, и они уходят реже. Это первое прямое

подтверждение, что рычаг «активация» действительно двигает выручку.

29.3 Суммарный вклад за год

ФОРМУЛА 29.1 · РЕАЛИЗОВАННАЯ ДОЛЯ СУММЫ ЭФФЕКТОВ

$$\rho = \frac{\Delta Y_{\text{holdout}}}{\Sigma\, \Delta Y_{\text{i}}} \tag{29.1}$$

где

$\Delta Y_{\text{holdout}}$ — разница с глобальным holdout –

$\Sigma\, \Delta Y_{\text{i}}$ — сумма эффектов запущенных экспериментов на ту же метрику –

```
Отток платящих: сумма эффектов 7 запусков -2,9 п.п.; глобальный holdout показал -2,1 п.п. → ρ ≈ 72%
```

Сумма эффектов отдельных тестов на отток составила 2,9 п.п., а реальное снижение относительно глобального holdout — 2,1 п.п. Остальное съели перекрытия между изменениями и угасание новизны. Ксения стала планировать цели с поправкой: ожидать примерно 70% от суммы тестов.

29.4 Итог года «Формы»

ПОКАЗАТЕЛЬ	НАЧАЛО	ЧЕРЕЗ 12 МЕС.
Тренировка в 1-й день	34%	40%
Триал → оплата	41%	44,5%
Отток платящих	11%	8,9%
Платящих	64 000	87 400
MRR	33,3 млн ₽	45,4 млн ₽
Экспериментов	—	46, из них 14 запущено

ПРАВИЛО

Сумма побед — не результат. Результат — разница с теми, кто ничего не получил. Держите глобальный holdout хотя бы на одну точку продукта, чтобы видеть реальный вклад программы.

МИРОВОЙ КЕЙС Netflix и Spotify — публикации команд экспериментов

Долгосрочные контрольные группы

Netflix и Spotify описывали использование долгосрочных holdout-групп, чтобы оценивать накопленный эффект рекомендательных и интерфейсных изменений на удержание.

Обе компании отмечали, что эффект, измеренный за несколько недель, часто отличается от многомесячного, и для ключевых решений смотрят на долгосрочный.

ПЛОХО

Сложить эффекты

«14 побед дали в сумме +18% к выручке».

Реальный прирост неизвестен.

ХОРОШО

Сравнить с holdout

«Глобальный holdout показывает -2,1 п.п. оттока — 72% от суммы тестов».

Цели планируются с поправкой.

29.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Нет holdout	Долгосрочный эффект неизвестен	5% на 8–12 недель
Суммировать эффекты	Переоценка вклада	Глобальный holdout
Holdout навсегда	Часть пользователей без улучшений	Срок и ротация

29.6 Как устроен глобальный holdout «Формы»

ПРАВИЛА

1 **Доля**
4% новых пользователей каждого квартала не получают ни одного запуска.

ПРАВИЛА

2 **Срок**
Квартал плюс 8 недель наблюдения; затем группа получает все изменения.

3 **Метрики**
Платящие на 1 000 установок, отток M2, MRR на когорту.

✓ **Цена**
По оценке, около 0,4% выручки квартала — плата за знание реального эффекта.

ПРИМЕР

Стриминг

Сервис сложил эффекты 20 выигравших тестов за год и получил +25% к времени просмотра. Глобальный holdout показал +11%. Разница объяснялась пересечениями: несколько тестов улучшали одну и ту же рекомендацию разными способами.

29.7 Вопросы для самопроверки

- Что такое holdout и чем глобальный holdout отличается от обычного?
- Почему сумма эффектов тестов больше реального прироста?
- Как считать реализованную долю эффекта?
- Сколько держать holdout?
- Как использовать реализованную долю при планировании?

ПРАКТИКА 29 после главы 29

Оцените долгосрочный эффект последнего запуска.

ЧТО СДЕЛАТЬ

01	Если holdout есть — сравните ключевые метрики через 8 недель.	☐
02	Сравните с эффектом в тесте.	☐
03	Посчитайте долю реализованного эффекта по формуле (29.1) для группы запусков.	☐
04	Запланируйте глобальный holdout на следующий квартал.	☐

РЕЗУЛЬТАТ Доля реализованного эффекта — честный коэффициент для планирования следующих целей.

30 Ретроспектива экспериментов

После неё вы раз в квартал разбираете программу экспериментов целиком — скорость, долю побед, качество гипотез, ошибки процесса — и меняете процесс, а не только бэклог.

30.1 Метрики программы · 30.2 Вопросы ретроспективы · 30.3 Кейс «Формы»: ретро второго квартала · 30.4 Точность оценок · 30.5 Анти-паттерны · 30.6 Бенчмарки · 30.7 Вопросы для самопроверки

Отчёт по эксперименту отвечает на вопрос, что мы узнали о продукте. Ретроспектива программы отвечает на другой вопрос: как мы работаем с гипотезами и что в этом процессе улучшить. Её проводят раз в квартал на всех тестах сразу. Именно здесь видно, что половина тестов застревает на настройке аналитики или что гипотезы из интервью выигрывают втрое чаще гипотез из мозгового штурма.

30.1 Метрики программы

Метрика	Q1	Q2	Q3	Q4
Экспериментов завершено	8	11	13	14
Доля выигравших	25%	27%	31%	36%
Медиана от гипотезы до старта, дней	19	14	9	7
Тестов с технической ошибкой	3	2	1	0
Тестов без решения через 2 недели	2	1	0	0
Реализованный эффект на MRR, млн ₽	+1,8	+3,1	+3,4	+3,8

30.2 Вопросы ретроспективы

Скорость	Где теряется время между гипотезой и стартом? Между концом теста и решением?
Качество гипотез	Какие источники дают выигрыши? Насколько точны были оценки эффекта?
Надёжность	Сколько тестов пришлось перезапускать и почему?
Влияние	Сколько реализованного эффекта дала программа? Двигаемся ли к цели?
Команда	Что мешает? Что стоит перестать делать?

30.3 Кейс «Формы»: ретро второго квартала

ЧТО НАШЛИ И ИЗМЕНИЛИ

1 **Источник побед**
Гипотезы из интервью и опросов выиграли в 5 случаях из 9, из мозговых штурмов — в 1 из 8.

2 **Узкое место**
От гипотезы до старта — 14 дней, из них 6 на настройку событий.

3 **Оценки**
Ожидаемый эффект в среднем завышен в 2,2 раза.

✓ **Изменения**
Обязательное основание из исследований для гипотез с RICE > 20 000; шаблон событий для типовых тестов; поправочный коэффициент 0,5 к оценкам.

ПРАВИЛО

Ретроспектива заканчивается не списком наблюдений, а 2–3 изменениями процесса с владельцами. Через квартал первым пунктом проверяется, сработали ли они.

30.4 Точность оценок

ФОРМУЛА 30.1 · КАЛИБРОВКА ОЦЕНОК ЭФФЕКТА

$$k = \text{медиана}\ \frac{\Delta_{\text{факт}}}{\Delta_{\text{оценка}}} \qquad (30.1)$$

где

$\Delta_{\text{факт}}$ — фактический эффект эксперимента — п.п.

$\Delta_{\text{оценка}}$ — ожидаемый эффект из гипотезы — п.п.

```
Q2: медиана по 11 тестам 0,45 → оценки завышены в ≈2,2 раза; в Q4 после поправки k = 0,86
```

МИРОВОЙ КЕЙС Google SRE, «Site Reliability Engineering», 2016

Безобвинительные разборы

Инженеры Google SRE описали практику разборов без поиска виноватых: цель — понять, как система допустила ошибку, а не кто её сделал.

Тот же принцип применим к экспериментам: тест с ошибкой в событиях — повод улучшить шаблон и проверку, а не упрекнуть аналитика.

ПЛОХО

Разбор итогов

«Провели 11 тестов, 3 выиграли, молодцы».

Процесс не меняется.

ХОРОШО

Разбор процесса

«Гипотезы из исследований выигрывают в 4 раза чаще; оценки завышены вдвое».

Два изменения процесса с владельцами.

30.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Ретро только по победам	Не видно проблем процесса	Метрики программы
Поиск виноватых	Ошибки скрываются	Безобвинительный формат
Нет действий	Ретро ради ретро	2–3 изменения с владельцами

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Без калибровки оценок	Завышение повторяется	Коэффициент (30.1)

30.6 Бенчмарки

МЕТРИКА ПРОГРАММЫ	ОРИЕНТИР	«ФОРМА» Q4
От гипотезы до старта	до 7–10 дней	7 дней
От конца теста до решения	до 7 дней	3 дня
Тестов с технической ошибкой	до 5%	0%
Калибровка оценок k	0,7–1,2	0,86

Ориентиры условны и зависят от продукта; важнее, что каждый показатель «Формы» улучшался квартал к кварталу после конкретных изменений процесса.

ПРИМЕР

Платформа объявлений

Ретроспектива показала, что 40% тестов запускаются через месяц после формулировки гипотезы из-за очереди на аналитика. Команда ввела шаблоны событий и самостоятельную настройку типовых тестов продактами — время до старта сократилось до недели.

30.7 Вопросы для самопроверки

- Чем ретроспектива программы отличается от отчёта о тесте?
- Какие метрики программы стоит отслеживать?
- Как калибровать оценки эффекта?
- Почему ретро должно заканчиваться изменениями процесса?
- Зачем безобвинительный формат?

ПРАКТИКА 30 после главы 30

Проведите ретроспективу экспериментов за последний квартал.

ЧТО СДЕЛАТЬ

01	Посчитайте метрики программы из таблицы.	☐
02	Разложите выигрыши по источникам гипотез.	☐
03	Посчитайте калибровку оценок по формуле (30.1).	☐
04	Выберите 2–3 изменения процесса и назначьте владельцев.	☐

РЕЗУЛЬТАТ Повторяйте раз в квартал — тренд метрик программы важнее их значения.

31 Обновление подходов к поиску идей

После неё вы поддерживаете постоянный поток гипотез из нескольких источников, регулярно пересматриваете, какие источники работают, и не застреваете в локальном оптимуме.

31.1 Источники идей
31.2 Выход из локального оптимума
31.3 Кейс «Формы»: тренировки с партнёром
31.4 Анти-паттерны
31.5 Карта отдачи точек
31.6 Вопросы для самопроверки

Через год работы с гипотезами у команды появляется опасная привычка: искать идеи там же, где они находились раньше. Онбординг уже оптимизирован, экран оплаты переписан пять раз, каждый новый тест даёт всё меньше. Это локальный оптимум. Чтобы из него выйти, нужно обновлять источники идей и время от времени делать крупные шаги.

31.1 Источники идей

ИСТОЧНИК	РЕГУЛЯРНОСТЬ	ДОЛЯ ВЫИГРЫШЕЙ В «ФОРМЕ»
Интервью и юзабилити	2 цикла в квартал	45%
Опросы в продукте	постоянно	38%
Анализ воронки и когорт	раз в месяц	33%
Результаты прошлых тестов	после каждого теста	35%
Конкуренты и рынок	раз в квартал	22%
Обращения в поддержку	раз в месяц	30%
Мозговой штурм команды	раз в квартал	12%

31.2 Выход из локального оптимума

Мелкие улучшения похожи на подъём на ближайший холм: каждый шаг вверх, но вершина может быть невысокой. Чтобы найти более высокую гору, нужны шаги, которые сначала

могут увести вниз: новый сценарий, другая модель монетизации, новая ценность для пользователя. В портфеле гипотез «Формы» с третьего квартала 20% тестов — такие крупные ставки.

31.3 Кейс «Формы»: тренировки с партнёром

К третьему кварталу тесты онбординга давали в среднем +0,8 п.п. — вдвое меньше, чем весной. На ретро Лера предложила новый источник: дневниковое исследование двух недель жизни регулярных пользователей. Оказалось, что 31% регулярных тренируются вместе с кем-то — партнёром, подругой, ребёнком — и делают это через один телефон. Отсюда выросла крупная гипотеза о совместных тренировках. Фейковая дверь показала 9,4% нажатий — втрое больше, чем у челленджей, — и прототип пошёл в разработку.

КАК ОБНОВИЛИ ПОИСК

1 **Сигнал**
Снижающийся эффект тестов в одной точке два квартала подряд.

2 **Новый источник**
Дневниковое исследование вместо очередных интервью об онбординге.

3 **Крупная ставка**
Совместные тренировки — новая ценность, а не улучшение экрана.

✓ **Правило**
Если медиана эффекта в точке падает вдвое, точка уходит на паузу, ресурсы — на новые источники.

ПРАВИЛО

Следите за отдачей точки продукта. Когда эффект тестов в ней устойчиво падает, вы приближаетесь к её локальному оптимуму, и дальше стоит искать в другом месте или менять сценарий целиком.

МИРОВОЙ КЕЙС Клейтон Кристенсен, «Competing Against Luck», 2016

Работа, которую нанимают сделать

Кристенсен предложил смотреть на продукт через «работу», которую человек нанимает его сделать в конкретных обстоятельствах. Хрестоматийный пример — молочный коктейль, который утром покупали как еду в долгой дороге.

Такой взгляд часто открывает идеи, которых не видно при оптимизации существующих экранов: в «Форме» работой оказалась не «тренировка», а «время вместе, которое полезно».

ПЛОХО

Шестой тест кнопки

«Попробуем ещё один текст на экране оплаты».

Эффекты всё меньше, команда скучает.

ХОРОШО

Новый источник

Дневниковое исследование нашло новую работу продукта.

Крупная гипотеза с потенциалом в разы больше.

31.4 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Один источник идей	Слепые зоны	Портфель источников
Только мелкие улучшения	Локальный оптимум	20% крупных ставок
Не измерять источники	Тратится время на слабые	Доля выигрышей по источнику
Идеи только от продакта	Узкий взгляд	Поддержка, продажи, разработка

31.5 Карта отдачи точек

ТОЧКА	МЕДИАНА ЭФФЕКТА Q1–Q2	МЕДИАНА Q3–Q4	РЕШЕНИЕ
Онбординг	+1,8 п.п.	+0,8 п.п.	Пауза, крупные ставки
Экран оплаты	+1,5 п.п.	+1,2 п.п.	Продолжаем
Напоминания	+1,1 п.п.	+1,6 п.п.	Наращиваем
Совместные тренировки	—	новая точка	Крупная ставка

Карта отдачи помогает распределять ёмкость: туда, где эффект растёт или стабилен, и прочь от исчерпанных точек.

ПРИМЕР

Приложение для медитаций

Команда два года оптимизировала экран оплаты, эффект тестов упал до долей процента. Дневниковое исследование показало, что люди используют приложение в основном для сна. Новая категория историй на ночь стала крупнейшим источником роста за следующий год.

31.6 Вопросы для самопроверки

- Что такое локальный оптимум в работе с гипотезами?
- Как понять, что точка продукта исчерпана?
- Какие источники идей дают больше выигрышей?
- Зачем нужны крупные ставки в портфеле?
- Как найти новую «работу» продукта?

ПРАКТИКА 31 после главы 31

Проверьте, не застряли ли вы в локальном оптимуме.

ЧТО СДЕЛАТЬ

- [ ] 01 Посчитайте медиану эффекта тестов по точкам продукта за два последних квартала.
- [ ] 02 Посчитайте долю выигрышей по источникам гипотез.
- [ ] 03 Выберите один новый источник идей на следующий квартал.
- [ ] 04 Заложите в портфель 1–2 крупные ставки.

РЕЗУЛЬТАТ Падающая отдача точки — не провал, а сигнал искать в другом месте.

32 Автоматизация сбора данных и тестирования

После неё вы автоматизируете повторяющиеся части цикла — настройку экспериментов, проверки здоровья, расчёт результатов, отчёты — и решаете, когда строить свою платформу, а когда брать готовую.

32.1 Что автоматизировать в первую очередь
32.2 Слой метрик
32.3 Своя платформа или готовая
32.4 Кейс «Формы»: от 5 дней к 1
32.5 Анти-паттерны
32.6 Бенчмарки
32.7 Вопросы для самопроверки

Когда экспериментов становится больше десяти в квартал, ручные операции начинают тормозить всю программу: аналитик пишет одинаковые SQL-запросы, вручную проверяет SRM и собирает отчёт в документе. Автоматизация не меняет логику экспериментов, но освобождает время для того, что требует головы: гипотез и интерпретации.

32.1 Что автоматизировать в первую очередь

ЧАСТЬ ЦИКЛА	ВРУЧНУЮ	АВТОМАТИЧЕСКИ
Расчёт выборки	Калькулятор и таблица	Форма в карточке гипотезы: p, MDE → n и недели
Раздача вариантов	Флаг + код в приложении	Сервис экспериментов с конфигом без релиза
Проверки здоровья	SQL раз в день	SRM, события, ошибки — алерт в чат
Расчёт метрик	Новый запрос на каждый тест	Слой метрик: тест выбирает метрики из каталога
Отчёт	Документ вручную	Черновик отчёта по шаблону из данных теста
База знаний	Копировать в вики	Отчёт и решение сохраняются автоматически с тегами

32.2 Слой метрик

Главная инвестиция — единый каталог метрик: каждая метрика описана один раз (события, окно, знаменатель), и любой эксперимент выбирает метрики из каталога. Это убирает споры о том, чья цифра правильная, и позволяет считать целевые и защитные метрики для любого теста без новых запросов.

```
metric: first_day_workout_rate
 numerator:   users with workout_started within 24h of exposure
 denominator: exposed users
 type:        proportion · direction: up
metric: trial_to_paid
 numerator:   users with subscription_paid within 8 days of trial_started
 denominator: exposed users with trial_started
 type:        proportion · window: 8d · guardrail: refund_rate_14d
```

32.3 Своя платформа или готовая

ВАРИАНТ	КОГДА ПОДХОДИТ	РИСК
Готовый сервис экспериментов	До 50–100 тестов в год, стандартные метрики	Ограничения в метриках и данных, стоимость при росте
Готовая раздача + свой расчёт в хранилище	Данные уже в хранилище, есть аналитики	Поддержка запросов
Своя платформа	Сотни тестов, сложные метрики, требования к данным	Год разработки и команда поддержки

32.4 Кейс «Формы»: от 5 дней к 1

В начале года настройка одного теста занимала у Артура до пяти дней: события, запросы, дашборд, проверки. Команда выбрала готовый сервис раздачи вариантов и построила свой расчёт в хранилище: каталог из 34 метрик, ежедневные проверки SRM и защитных с алертами, черновик отчёта из шаблона. К концу года настройка занимала один день, а число тестов в квартал выросло с 8 до 14 без нового аналитика.

ВАЖНО · ТИПИЧНАЯ ОШИБКА

Начинать с покупки дорогой платформы до того, как появился процесс. Инструмент ускоряет хороший процесс и консервирует плохой. Сначала шаблоны, план эксперимента и регулярность, потом автоматизация того, что повторяется.

МИРОВОЙ КЕЙС Публикации Microsoft ExP, Netflix XP, Uber, Spotify

Платформы экспериментов крупных компаний

Компании, проводящие тысячи экспериментов в год, описывали свои платформы: каталог метрик, автоматические проверки SRM, вычисление интервалов с понижением дисперсии и автоматические отчёты.

Общий мотив публикаций: платформа появилась после того, как ручной процесс стал узким местом, а не до него.

ПЛОХО

Ручная рутина

Новый SQL на каждый тест, SRM проверяется «когда вспомнили».

Аналитик — узкое место программы.

ХОРОШО

Автоматизация повторяющегося

Каталог метрик, алерты здоровья, черновик отчёта.

Время аналитика — на гипотезы и интерпретацию.

32.5 Анти-паттерны

АНТИ-ПАТТЕРН	ЧЕМ ВРЕДИТ	ЧТО ДЕЛАТЬ
Платформа до процесса	Дорогой инструмент без пользы	Сначала процесс
Метрики в каждом тесте заново	Расхождения цифр	Каталог метрик
Автоматический вывод «победа»	Решения без интерпретации	Автоматизировать расчёт, а не решение

32.6 Бенчмарки

ЧТО АВТОМАТИЗИРОВАЛИ	ЭКОНОМИЯ ВРЕМЕНИ АНАЛИТИКА НА ТЕСТ
Каталог метрик	≈ 1,5 дня
Проверки SRM и защитных	≈ 0,5 дня
Черновик отчёта	≈ 0,5 дня
Расчёт выборки в карточке	≈ 2 часа

Суммарно — около трёх дней на тест. При 14 тестах в квартал это 42 дня работы аналитика, которые ушли на исследования и интерпретацию вместо рутины.

ПРИМЕР

E-commerce

Компания купила дорогую платформу экспериментов при трёх тестах в квартал. Через год тестов стало два: процесс формулировки гипотез и плана не изменился. После внедрения шаблонов и регулярных встреч число тестов выросло до 12 — уже на той же платформе.

32.7 Вопросы для самопроверки

- Что автоматизировать в первую очередь?
- Зачем нужен каталог метрик?
- Когда строить свою платформу, а когда брать готовую?
- Почему платформа до процесса — ошибка?
- Что из цикла экспериментов не стоит автоматизировать?

ПРАКТИКА 32 после главы 32

Найдите и автоматизируйте самую повторяющуюся часть цикла.

ЧТО СДЕЛАТЬ

01	Засеките время на каждый этап последних трёх экспериментов.	☐
02	Выберите этап, который повторяется одинаково и занимает больше всего времени.	☐
03	Опишите 5–10 главных метрик в едином каталоге.	☐
04	Настройте автоматическую проверку SRM и защитных с алертом.	☐

РЕЗУЛЬТАТ Цель — настройка типового теста за один день, а решение по-прежнему за людьми.

A Шаблоны документов

Шаблоны из глав книги в виде, готовом к копированию: заполните их для своего продукта.

A.1 Цель и дерево метрик · A.2 Карточка гипотезы · A.3 План эксперимента · A.4 Журнал эксперимента · A.5 Отчёт об эксперименте · A.6 Расчёт выборки

A.1 Цель и дерево метрик

```
Цель:         <результат> с <A> до <B> к <дата>
Границы:      <что нельзя ухудшать, пороги>
North Star:   <метрика ценности> · сейчас <значение>
Ветки:        <новые> · <удержание> · <монетизация>
Рычаги:       <метрика шага> <A> → <B>  (3 штуки максимум)
Защитные:     <2–3 метрики с порогами>
```

A.2 Карточка гипотезы

```
Г—<N> · <короткое название>
Если мы     <изменение>
для         <аудитория, точка сценария>,
то          <целевая метрика> изменится с <A> до <B>,
потому что <основание: данные, исследование, конкурент>.
Ошиблись, если <критерий опровержения>; защитные: <…>
Рычаг · тип · владелец · R · I · C · E · RICE · метод · точка · статус
```

A.3 План эксперимента

```
Э—<N> · Г—<N>
Варианты:    A — <контроль> · B — <изменение>
Аудитория:   <кто> · главный сегмент <…> · исследовательские <…>
Деление:     по <единица>, <доли>, точка — <экран/событие>
Целевая:     <метрика> (база <p>, MDE <δ>)
Вспомогат.:  <…> · Защитные: <…> с порогами остановки
Выборка:     <n> на группу · <недель> + окно ожидания <дней>
Решение:     запуск, если <условие>; отказ, если <условие>
События:     <список> · проверены на сотрудниках <дата>
Даты:        старт · конец набора · анализ
```

A.4 Журнал эксперимента

```
<дата>  <событие: релиз, акция, сбой, SRM> — <решение: продлить, исключить период,
остановить>
```

A.5 Отчёт об эксперименте

```
Э—<N> · <название> · <ЗАПУСКАЕМ | ДОРАБАТЫВАЕМ | ОТКАЗЫВАЕМСЯ>
Гипотеза · даты · участники
Результат:  <Δ> (<интервал>), p
Механизм:   <вспомогательные метрики>
Защитные:   <…> · Сегменты: <только объявленные>
Сбои:       <из журнала>
Решение:    <что и когда> · holdout <доля, срок>
Знание:     <вывод для других гипотез>
Теги и ссылки: точка · рычаг · тип · исход · план · дашборд · запрос
```

A.6 Расчёт выборки

ВХОД	ЗНАЧЕНИЕ	ПРИМЕЧАНИЕ
Базовая конверсия p	<…>	за последние 4 недели
MDE δ	<…>	из оценки эффекта, глава 11
α / мощность	5% / 80%	$n \approx 16 \cdot p(1-p)/\delta^2$

ВХОД	ЗНАЧЕНИЕ	ПРИМЕЧАНИЕ
n на группу	<…>	
Трафик в неделю	<…>	в точке теста
Недель набора	<…>	округлить до целых
Окно ожидания	<…>	для отложенной конверсии

Б Чек-листы по этапам

Проверочные списки для каждого этапа цикла гипотез. Отмечайте пункты по порядку.

Б.1 Цель и контекст · Б.2 Данные и гипотезы · Б.3 Перед запуском · Б.4 Во время теста · Б.5 После теста · Б.6 Раз в квартал

Б.1 Цель и контекст

- [ ] Цель с числом «с — до», сроком и границами (глава 1).
- [ ] Выручка разложена формулой до 2–3 рычагов (глава 1).
- [ ] Выбрана North Star, связь с выручкой проверена на истории (глава 2).
- [ ] Посчитана ёмкость точек теста (глава 3).

Б.2 Данные и гипотезы

- [ ] Воронка, когорты и сегменты дали 3 вопроса «почему» (глава 4).
- [ ] Интервью о прошлом поведении, 8–12 на сегмент (глава 5).
- [ ] Находки проверены опросом в точке сценария (глава 6).
- [ ] Каждая гипотеза по шаблону: изменение, аудитория, «с — до», причина, опровержение (глава 8).
- [ ] RICE посчитан с охватом из аналитики и шкалой уверенности (глава 9).

Б.3 Перед запуском

- [ ] Метод выбран с наибольшей доступной уверенностью (глава 14).

- [ ] Деление в точке изменения, сегменты объявлены заранее (глава 15).
- [ ] Выборка рассчитана, длительность — целые недели плюс окно ожидания (глава 16).
- [ ] План записан и согласован, правило решения зафиксировано (глава 17).
- [ ] События проверены на сотрудниках и сверены с внешним источником (главы 17–18).

Б.4 Во время теста

- [ ] SRM проверен в первые сутки (глава 18).
- [ ] Здоровье и защитные — каждый день, целевая скрыта (глава 19).
- [ ] Сбои записаны в журнал; исключения только симметричные (глава 20).

Б.5 После теста

- [ ] Эффект с интервалом сравнён с порогом практической значимости (глава 21).
- [ ] Механизм проверен вспомогательными метриками (глава 22).
- [ ] Воронка досчитана до денег, побочные эффекты проверены (глава 23).
- [ ] Решение по матрице за неделю (глава 24).
- [ ] Отчёт в базе знаний, бэклог обновлён (главы 25–26).
- [ ] Раскатка ступенями с holdout, флаг удалён в срок (главы 27–28).

Б.6 Раз в квартал

- [ ] Долгосрочный эффект по holdout (глава 29).
- [ ] Ретроспектива с метриками программы и калибровкой оценок (глава 30).
- [ ] Отдача точек и источников идей пересмотрена (глава 31).

B Глоссарий

Термины книги по-русски, рядом английский оригинал, как они встречаются в инструментах и статьях.

A/A-тест	Эксперимент с одинаковыми вариантами для проверки системы экспериментов.
A/B-тест	Эксперимент со случайным делением пользователей на контроль и вариант.
ARPPU (average revenue per paying user)	Средний платёж платящего пользователя за период.
Holdout	Группа, которая долго не получает запущенное изменение; глобальный holdout — ни одного изменения.
MDE (minimum detectable effect)	Минимальный эффект, который тест способен обнаружить при заданных α и мощности.
MRR (monthly recurring revenue)	Ежемесячная повторяющаяся выручка подписок.
North Star	Главная метрика, отражающая полученную пользователем ценность и ведущая к выручке.
p-value	Вероятность увидеть такую или большую разницу, если эффекта нет.
RICE	Приоритизация: охват × влияние × уверенность / трудозатраты.
SRM (sample ratio mismatch)	Несоответствие размеров групп заданному делению — признак технической ошибки.

Вспомогательная метрика (secondary)	Метрика, которая объясняет механизм изменения целевой.
Гипотеза	Проверяемое утверждение: изменение, аудитория, эффект, причина, критерий опровержения.
Доверительный интервал	Диапазон, в котором с заданной надёжностью лежит настоящий эффект.
Защитная метрика (guardrail)	Метрика, ухудшение которой запрещает запуск независимо от целевой.
Квазиэксперимент	Сравнение без случайного деления по пользователям, например разность разностей по регионам.
Мощность (power)	Вероятность обнаружить эффект, если он есть; обычно 80%.
Множественные сравнения	Рост вероятности ложной находки при проверке многих метрик, вариантов или сегментов.
Подглядывание (peeking)	Решение по промежуточным результатам без поправки; повышает долю ложных побед.
Разность разностей (DiD)	Изменение метрики в тестовом кластере минус изменение в контрольном.
Уровень значимости α	Допустимая вероятность ложной победы; обычно 5%.
Фейковая дверь (fake door)	Элемент интерфейса для функции, которой ещё нет; измеряет спрос.
Флаг функции (feature flag)	Переключатель в коде, определяющий, какой вариант видит пользователь.
Целевая метрика (primary)	Метрика, по которой принимается решение по эксперименту.
Экспозиция (exposure)	Событие: пользователь впервые увидел вариант эксперимента.

Эффект новизны	Временная реакция на новое, которая угасает со временем.

КОНЕЦ ГАЙДА

Теперь проверьте себя

Тест по теоретическим основам и шаблоны к главам лежат на странице гайда.

- [ ] Пройдите тест по гайду — онлайн
- [ ] Возьмите шаблоны документов — с. 155
- [ ] Пройдите чек-листы по этапам — с. 158

Цены рекламы, тарифы и доступность сервисов указаны как ориентиры и устаревают быстрее остального текста. Числовая модель сквозного продукта вымышлена, но внутренне непротиворечива.